Aula 4 — EDA Profissional (Versão Avançada) - Para Aula

Dataset: Airbnb NYC

Objetivos Desta Aula

- **Explorar um dataset real de mercado:** Entender a estrutura e o conteúdo de dados reais.
- **Detectar e tratar valores faltantes e outliers:** Aprender técnicas para limpar e preparar os dados.
- **Realizar análise por categoria e por localização:** Investigar padrões e tendências em diferentes segmentos e regiões.
- **Construir gráficos profissionais e informativos:** Utilizar bibliotecas avançadas para visualizações de alta qualidade.
- **Introduzir correlação entre variáveis:** Entender as relações entre diferentes atributos do dataset.
- **Engenharia de Features:** Criar novas variáveis para enriquecer a análise.
- **Análise Geoespacial:** Visualizar dados em um contexto geográfico.
- **Interpretar e comunicar insights:** Extrair conclusões significativas dos dados.

1) Importação das bibliotecas Essenciais

Nesta seção, importamos todas as bibliotecas Python necessárias para a Análise Exploratória de Dados (EDA).

- `pandas` : Para manipulação e análise de dados em formato de DataFrame.
- `matplotlib.pyplot` : Para a criação de gráficos estáticos.
- `seaborn` : Baseado no matplotlib, oferece uma interface de alto nível para criar gráficos estatísticos atraentes e informativos.
- `numpy` : Para operações numéricas e matemáticas, especialmente útil para lidar com arrays e cálculos estatísticos.
- `folium` : Para criar mapas interativos e visualizar dados geoespaciais.

In [1]:
```
# Importe aqui as bibliotecas necessárias: pandas, matplotlib.pyplot,
seaborn, numpy, folium
# Configure os estilos de visualização (sns.set_style, plt.rcParams)
import pandas as pd
from matplotlib import pyplot as plt
import seaborn as sns
import numpy as np
import folium
from folium.plugins import MarkerCluster
```

2) Carregar o Dataset

Carregamos o dataset do Airbnb NYC a partir de um arquivo CSV. Este é o primeiro passo para qualquer análise de dados, onde os dados brutos são lidos e transformados em um DataFrame do pandas para fácil manipulação.

In [2]:
```
# Carregue o arquivo CSV "AB_NYC_2019.csv" em um DataFrame do pandas
# Exiba as primeiras linhas do DataFrame para uma visão inicial dos
dados
df = pd.read_csv("../AB_NYC_2019.csv")
```

3) Visão Geral e Estrutura dos Dados

Esta seção fornece uma visão geral rápida do dataset, incluindo suas dimensões, tipos de dados e um resumo estatístico. Isso nos ajuda a entender a estrutura dos dados e identificar possíveis problemas, como valores ausentes ou tipos de dados incorretos.

In [3]:
```
# Exiba o número de linhas e colunas do DataFrame (df.shape)
# Exiba informações sobre o DataFrame, incluindo tipos de dados e
valores não-nulos (df.info())
# Exiba estatísticas descritivas para as colunas numéricas
(df.describe())
# Exiba estatísticas descritivas para todas as colunas (incluindo
categóricas) (df.describe(include="all"))
linhas, colunas = df.shape
print("Número de linhas: ", linhas)
print("Número de colunas: ", colunas)
print("\n")
print(df.info())
print(df.describe())
print(df.describe(include="all"))
```

```
Número de linhas:  48895
Número de colunas:  16


<class 'pandas.DataFrame'>
RangeIndex: 48895 entries, 0 to 48894
Data columns (total 16 columns):
 #   Column                          Non-Null Count  Dtype
---  ------                          --------------  -----
 0   id                              48895 non-null  int64
 1   name                            48879 non-null  str
 2   host_id                         48895 non-null  int64
 3   host_name                       48874 non-null  str
 4   neighbourhood_group             48895 non-null  str
 5   neighbourhood                   48895 non-null  str
 6   latitude                        48895 non-null  float64
 7   longitude                       48895 non-null  float64
 8   room_type                       48895 non-null  str
 9   price                           48895 non-null  int64
 10  minimum_nights                  48895 non-null  int64
 11  number_of_reviews               48895 non-null  int64
 12  last_review                     38843 non-null  str
 13  reviews_per_month               38843 non-null  float64
 14  calculated_host_listings_count  48895 non-null  int64
 15  availability_365                48895 non-null  int64
dtypes: float64(3), int64(7), str(6)
memory usage: 6.0 MB
None
                 id       host_id      latitude     longitude
price  \
count  4.889500e+04  4.889500e+04  48895.000000  48895.000000
48895.000000
mean   1.901714e+07  6.762001e+07     40.728949    -73.952170
152.720687
std    1.098311e+07  7.861097e+07      0.054530      0.046157
240.154170
min    2.539000e+03  2.438000e+03     40.499790    -74.244420
```

```
0.000000
25%    9.471945e+06  7.822033e+06     40.690100    -73.983070
69.000000
50%    1.967728e+07  3.079382e+07     40.723070    -73.955680
106.000000
75%    2.915218e+07  1.074344e+08     40.763115    -73.936275
175.000000
max    3.648724e+07  2.743213e+08     40.913060    -73.712990
10000.000000

       minimum_nights  number_of_reviews  reviews_per_month  \
count    48895.000000       48895.000000       38843.000000
mean         7.029962          23.274466           1.373221
std         20.510550          44.550582           1.680442
min          1.000000           0.000000           0.010000
25%          1.000000           1.000000           0.190000
50%          3.000000           5.000000           0.720000
75%          5.000000          24.000000           2.020000
max       1250.000000         629.000000          58.500000

       calculated_host_listings_count  availability_365
count                    48895.000000      48895.000000
mean                         7.143982        112.781327
std                         32.952519        131.622289
min                          1.000000          0.000000
25%                          1.000000          0.000000
50%                          1.000000         45.000000
75%                          2.000000        227.000000
max                        327.000000        365.000000
                  id            name       host_id host_name  \
count   4.889500e+04           48879  4.889500e+04     48874
unique           NaN           47905           NaN     11452
top              NaN  Hillside Hotel           NaN   Michael
freq             NaN              18           NaN       417
mean    1.901714e+07             NaN  6.762001e+07       NaN
std     1.098311e+07             NaN  7.861097e+07       NaN
min     2.539000e+03             NaN  2.438000e+03       NaN
25%     9.471945e+06             NaN  7.822033e+06       NaN
50%     1.967728e+07             NaN  3.079382e+07       NaN
75%     2.915218e+07             NaN  1.074344e+08       NaN
max     3.648724e+07             NaN  2.743213e+08       NaN

       neighbourhood_group neighbourhood      latitude
longitude  \
count                48895         48895  48895.000000
48895.000000
unique                   5           221           NaN
NaN
top              Manhattan  Williamsburg           NaN
NaN
freq                 21661          3920           NaN
NaN
```

```
mean                   NaN           NaN     40.728949
-73.952170
std                    NaN           NaN      0.054530
0.046157
min                    NaN           NaN     40.499790
-74.244420
25%                    NaN           NaN     40.690100
-73.983070
50%                    NaN           NaN     40.723070
-73.955680
75%                    NaN           NaN     40.763115
-73.936275
max                    NaN           NaN     40.913060
-73.712990

              room_type         price  minimum_nights
number_of_reviews  \
count             48895  48895.000000    48895.000000
48895.000000
unique                3           NaN             NaN
NaN
top     Entire home/apt           NaN             NaN
NaN
freq              25409           NaN             NaN
NaN
mean                NaN    152.720687        7.029962
23.274466
std                 NaN    240.154170       20.510550
44.550582
min                 NaN      0.000000        1.000000
0.000000
25%                 NaN     69.000000        1.000000
1.000000
50%                 NaN    106.000000        3.000000
5.000000
75%                 NaN    175.000000        5.000000
24.000000
max                 NaN  10000.000000     1250.000000
629.000000

       last_review  reviews_per_month
calculated_host_listings_count  \
count        38843       38843.000000
48895.000000
unique        1764                NaN
NaN
top     2019-06-23                NaN
NaN
freq          1413                NaN
NaN
mean           NaN           1.373221
7.143982
```

```
std            NaN           1.680442
32.952519
min            NaN           0.010000
1.000000
25%            NaN           0.190000
1.000000
50%            NaN           0.720000
1.000000
75%            NaN           2.020000
2.000000
max            NaN          58.500000
327.000000

        availability_365
count       48895.000000
unique               NaN
top                  NaN
freq                 NaN
mean          112.781327
std           131.622289
min             0.000000
25%             0.000000
50%            45.000000
75%           227.000000
max           365.000000
```

4) Tratamento de Valores Faltantes

Valores faltantes são comuns em datasets reais e podem afetar a qualidade da análise. Nesta seção, identificamos e tratamos esses valores, decidindo entre remover, preencher com um valor específico (média, mediana, moda) ou usar métodos mais avançados.

In [4]:
```
# Calcule e exiba a quantidade de valores faltantes por coluna
print("Antes das alteracoes: ")
print(df.isnull().sum())

# Preencha os valores faltantes nas colunas `name` e `host_name` com
"unknown"
df["name"] = df["name"].fillna("unknown")
df["host_name"] = df["host_name"].fillna("unknown")

# Preencha os valores faltantes na coluna `reviews_per_month` com 0
df["reviews_per_month"] = df["reviews_per_month"].fillna(0)

# Converta a coluna `last_review` para datetime e preencha os valores
faltantes com uma data de referência (e.g., "2010-01-01")
df["last_review"] = pd.to_datetime(df["last_review"])
df["last_review"] = df["last_review"].fillna(pd.Timestamp("2010-01-01"))

# Verifique novamente os valores faltantes após o tratamento
print("\nDepois das alteracoes: ")
print(df.isnull().sum())
```

```
Antes das alteracoes:
id                                  0
name                               16
host_id                             0
host_name                          21
neighbourhood_group                 0
neighbourhood                       0
latitude                            0
longitude                           0
room_type                           0
price                               0
minimum_nights                      0
number_of_reviews                   0
last_review                     10052
reviews_per_month               10052
calculated_host_listings_count      0
availability_365                    0
dtype: int64

Depois das alteracoes:
id                                0
name                              0
host_id                           0
host_name                         0
neighbourhood_group               0
neighbourhood                     0
latitude                          0
longitude                         0
room_type                         0
price                             0
minimum_nights                    0
```

```
number_of_reviews                 0
last_review                       0
reviews_per_month                 0
calculated_host_listings_count    0
availability_365                  0
dtype: int64
```

5) Detecção e Tratamento de Outliers

Outliers são pontos de dados que se desviam significativamente de outras observações. Eles podem distorcer análises estatísticas e modelos de machine learning. Nesta seção, identificamos e tratamos outliers em variáveis numéricas chave, como `price` e `minimum_nights`. Usaremos o método do Intervalo Interquartil (IQR) para uma abordagem robusta.

In [5]:
```
# Defina uma função `remove_outliers_iqr` para detectar e remover
outliers usando o método IQR
def remove_outliers_iqr(df, coluna):
    q1 = df[coluna].quantile(0.25)
    q3 = df[coluna].quantile(0.75)

    iqr = q3 - q1

    limite_inferior = q1 - 1.5 * iqr
    limite_superior = q3 + 1.5 * iqr

    new_df = df[(df[coluna] < limite_superior) & (df[coluna] >
limite_inferior)]
    return new_df


# Aplique a função para tratar outliers nas colunas `price`,
`minimum_nights` e `number_of_reviews`
new_df = remove_outliers_iqr(df, "price")
new_df = remove_outliers_iqr(new_df, "minimum_nights")
new_df = remove_outliers_iqr(new_df, "number_of_reviews")


# Exiba as estatísticas descritivas antes e depois do tratamento para
cada coluna
print("Antes do tratamento")
print(df[["price", "minimum_nights", "number_of_reviews"]].describe())


print("\nDepois do tratamento")
print(new_df[["price", "minimum_nights",
"number_of_reviews"]].describe())



# Atualize o DataFrame principal com os dados limpos
df = new_df.copy()
```

```
Antes do tratamento
              price  minimum_nights  number_of_reviews
count  48895.000000    48895.000000       48895.000000
mean     152.720687        7.029962          23.274466
std      240.154170       20.510550          44.550582
min        0.000000        1.000000           0.000000
25%       69.000000        1.000000           1.000000
50%      106.000000        3.000000           5.000000
75%      175.000000        5.000000          24.000000
max    10000.000000     1250.000000         629.000000
```

```
Depois do tratamento
              price  minimum_nights  number_of_reviews
count  35103.000000    35103.000000       35103.000000
mean     119.322366        2.758824          12.250377
std       67.845778        1.904313          16.446665
min        0.000000        1.000000           0.000000
25%       65.000000        1.000000           1.000000
50%      100.000000        2.000000           5.000000
75%      155.000000        3.000000          17.000000
max      333.000000       10.000000          70.000000
```

6) Análise Exploratória de Dados (EDA) Aprofundada

Com os dados limpos, podemos agora aprofundar nossa análise, explorando as distribuições das variáveis, as relações entre elas e identificando padrões que podem gerar insights valiosos.

6.1) Distribuição de Preços

Vamos visualizar a distribuição dos preços dos aluguéis para entender a faixa de valores e identificar a concentração de preços.

In [6]:
```
plt.figure(figsize=(12, 6))

# Histograma
plt.subplot(1, 2, 1)
sns.histplot(x=df["price"], kde=True)
plt.title("Distribuição dos Preços")
plt.xlabel("Preço")
plt.ylabel("Frequência")


# Boxplot
plt.subplot(1, 2, 2)
sns.boxplot(x=df["price"])
plt.title("Boxplot dos Preços")
plt.xlabel("Preço")

plt.tight_layout()
plt.show()
```

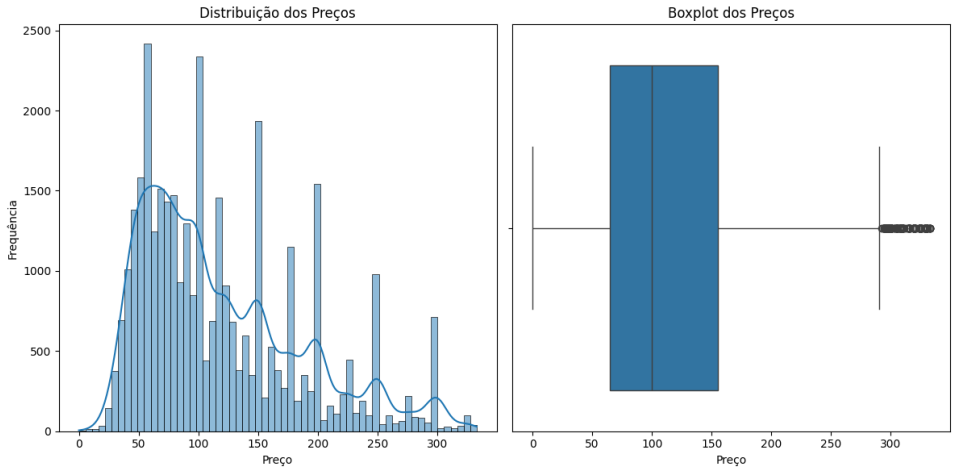

6.2) Análise por Tipo de Quarto (`room_type`)

Entender a distribuição dos tipos de quartos e como eles se relacionam com o preço é crucial para proprietários e hóspedes.

In [7]:
```
# Crie um gráfico de contagem dos tipos de quarto usando `sns.countplot`
plt.figure(figsize=(12, 5))
plt.subplot(1,2,1)
plt.title("Distribuicao dos tipos de quartos")
plt.ylabel("Frequencia")
plt.xlabel("Tipos de quarto")
sns.countplot(x=df["room_type"])
plt.show()

# Crie um boxplot do preço por tipo de quarto usando `sns.boxplot`
plt.figure(figsize=(12,5))
plt.subplot(1,2,2)
plt.title("Boxplot do preco por tipo de quarto")
plt.xlabel("Tipo de quarto")
plt.ylabel("Preco")
sns.boxplot(x=df["room_type"], y=df["price"])
plt.tight_layout()
plt.show()
# Adicione títulos e rótulos aos gráficos
```

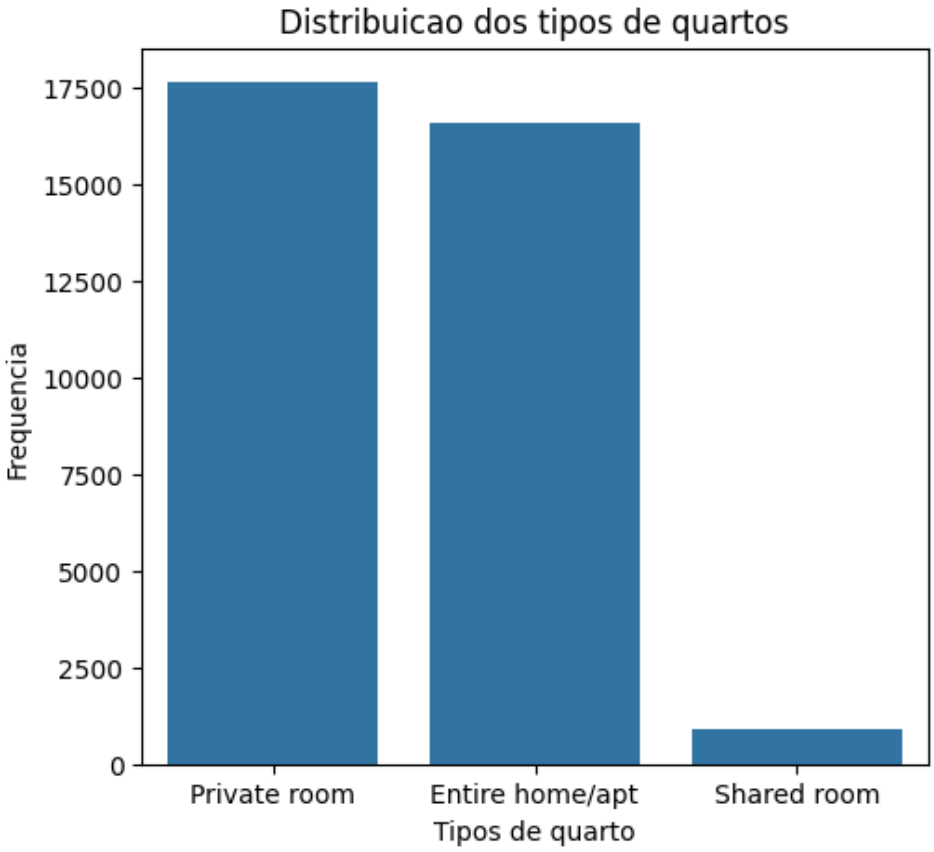

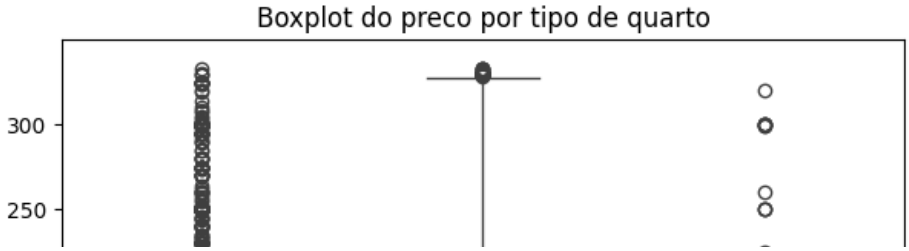

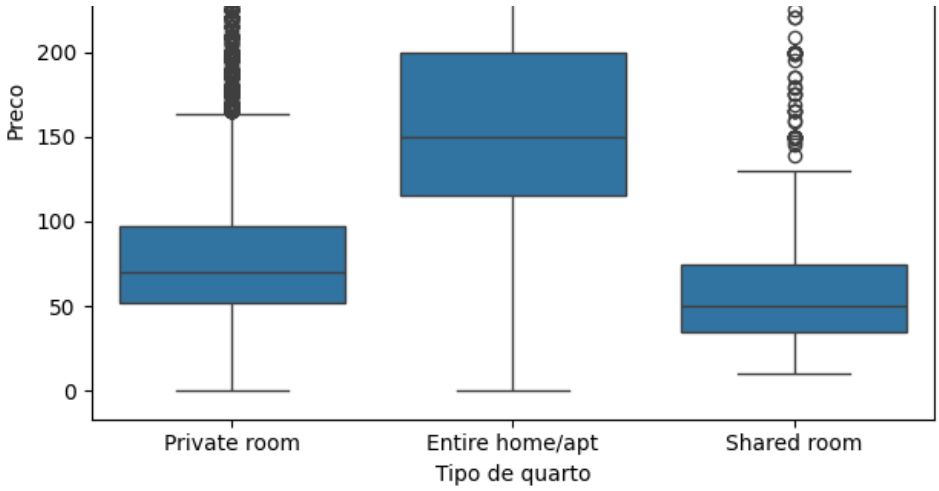

6.3) Análise por Grupo de Bairro (`neighbourhood_group`)

A localização é um dos fatores mais importantes no mercado imobiliário. Vamos analisar como os preços e a disponibilidade variam entre os diferentes grupos de bairros de NYC.

In [8]:
```
# Crie um gráfico de contagem de anúncios por grupo de bairro usando
`sns.countplot`
# Crie um boxplot do preço por grupo de bairro usando `sns.boxplot`
# Adicione títulos e rótulos aos gráficos
plt.figure(figsize=(12, 6))
plt.subplot(1, 2, 1)
plt.title("Distribuicao de anuncios por grupo de bairro")
plt.xlabel("Grupo de bairro")
plt.ylabel("Quantidade de anuncios")
sns.countplot(x=df["neighbourhood_group"])
plt.show()

plt.figure(figsize=(12, 6))
plt.subplot(1, 2, 2)
plt.title("Distribuicao de preco por grupo de bairro")
plt.xlabel("Grupo de bairro")
plt.ylabel("Preco")
sns.boxplot(x=df["neighbourhood_group"], y=df["price"])
plt.show()
```

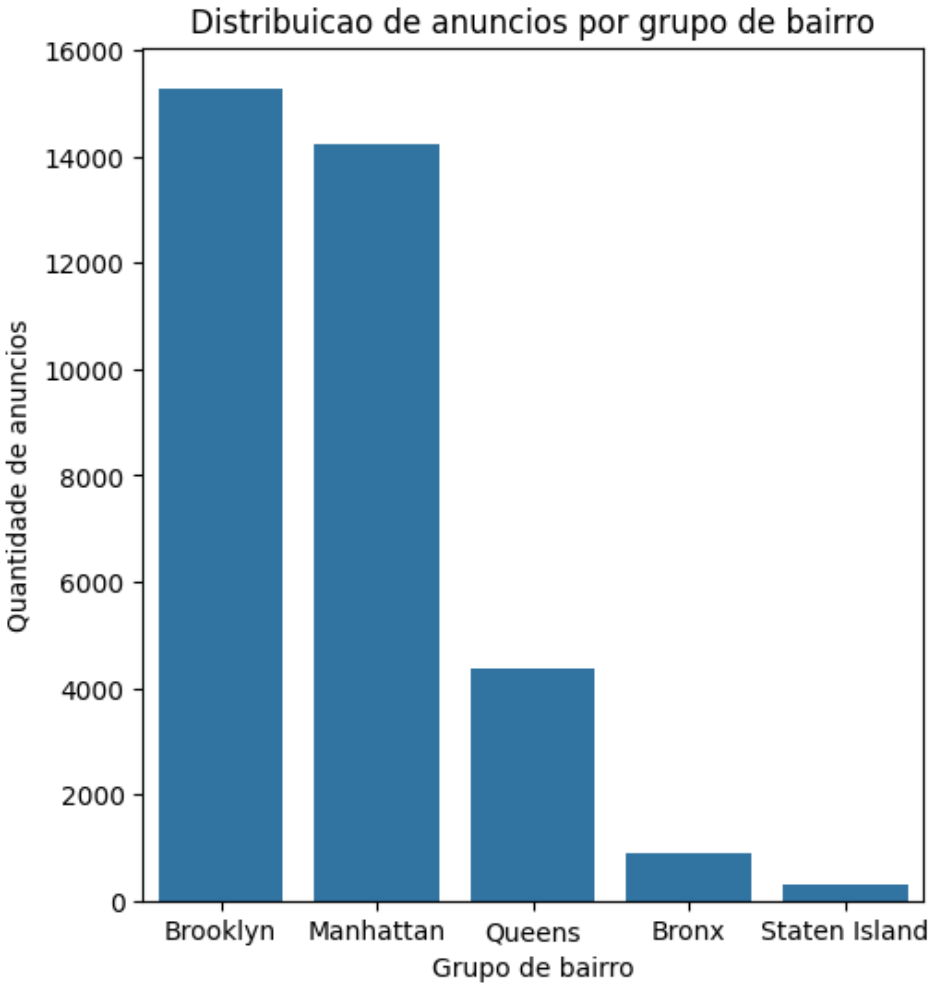

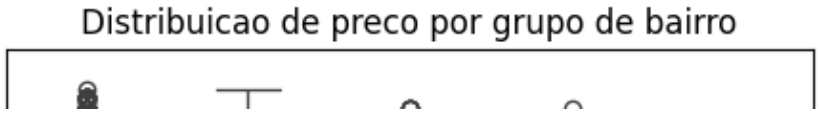

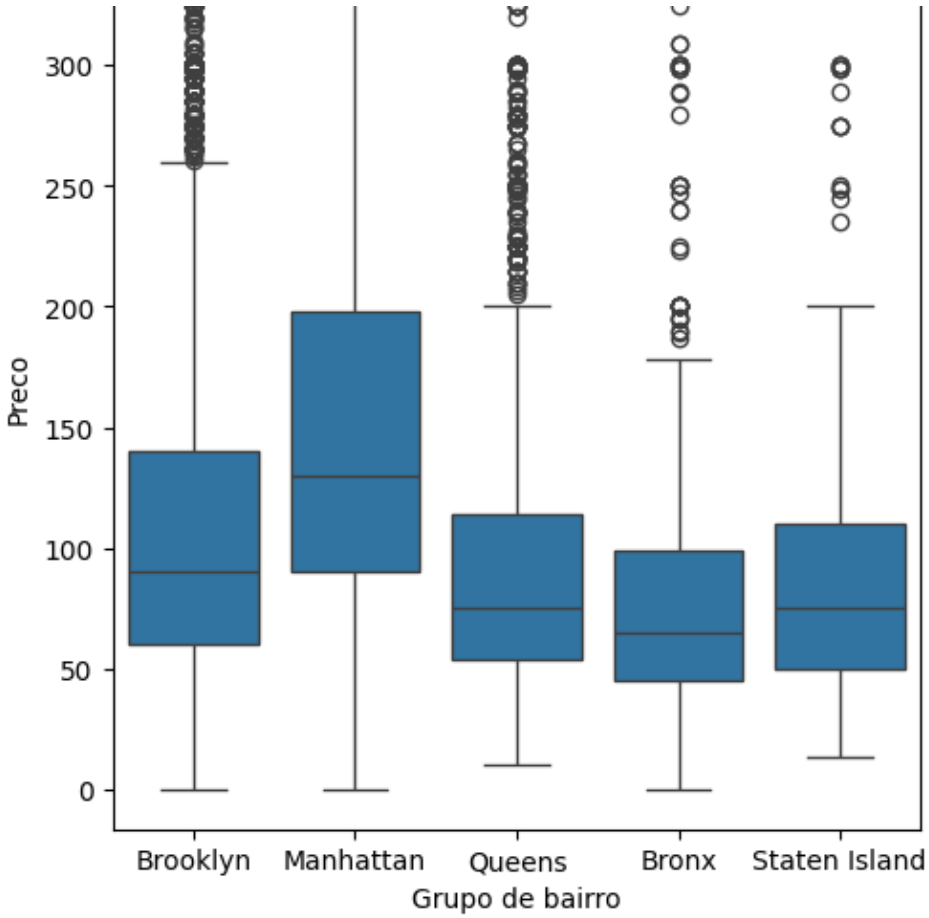

6.4) Top 10 Bairros com Mais Anúncios

Identificar os bairros com maior concentração de anúncios pode indicar áreas de alta demanda ou popularidade.

In [9]:
```
# Calcule os 10 bairros com mais anúncios
bairros_mais_anuncios = df["neighbourhood"].value_counts().head(10)
bairros = bairros_mais_anuncios.reset_index()
bairros.columns = ["neighbourhood", "count"]
# Crie um gráfico de barras para visualizar esses bairros usando
`sns.barplot`
plt.figure(figsize=(15, 6))
sns.barplot(data=bairros, x="neighbourhood", y="count")
plt.title("10 bairros com mais anuncios")
plt.ylabel("Contagem")
plt.xlabel("Vizinhanca")
plt.tight_layout()
plt.show()
# Adicione títulos e rótulos aos gráficos, e rotacione os rótulos do
eixo X se necessário
```

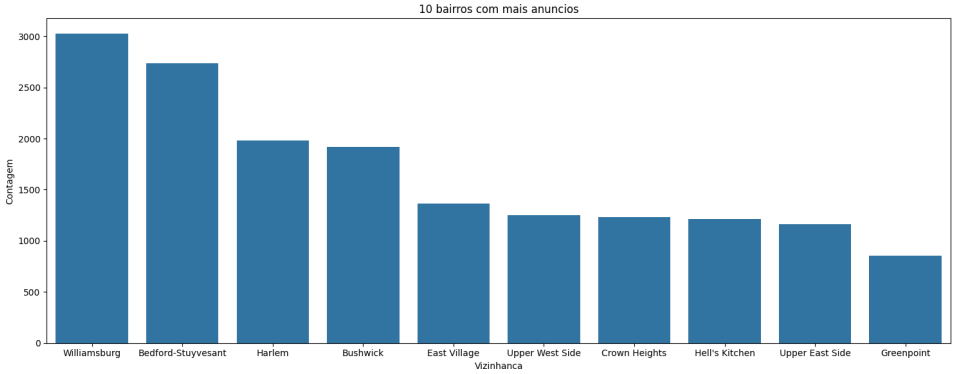

6.5) Análise Geoespacial dos Anúncios

Visualizar os anúncios em um mapa nos permite identificar clusters geográficos e entender a distribuição espacial dos imóveis.

In [ ]:
```
# Crie um mapa base de Nova York usando `folium.Map`
nyc = folium.Map(location=[40.7128, -74.0060], zoom_start=12)
# Adicione um `MarkerCluster` ao mapa
market_cluster = folium.plugins.MarkerCluster().add_to(nyc)
# Amostre uma parte do DataFrame (e.g., 5000 pontos) para melhor
performance na visualização

amostra = df.sample(n=5000, random_state=42)

# Adicione marcadores ao mapa para cada ponto amostrado, incluindo
informações no popup

for _, row in amostra.iterrows():
    folium.Marker(
        location=[row["latitude"], row["longitude"]],
        popup=f"""
        Neighbourhood: {row["neighbourhood"]}<br>
        Price: ${row["price"]}<br>
        Type: {row["room_type"]}
        """
    ).add_to(market_cluster)
# Salve o mapa em um arquivo HTML (e.g., "airbnb_nyc_map.html")
nyc.save("airbnb_nyc_map.html")
# (Opcional) Exiba o mapa diretamente no notebook se o ambiente suportar
```

7) Engenharia de Features

A engenharia de features envolve a criação de novas variáveis a partir das existentes para melhorar a capacidade preditiva dos modelos ou para obter novos insights. Aqui, criaremos algumas features simples.

7.1) `host_experience_days`

Calcularemos a experiência do anfitrião em dias, baseando-nos na data da última avaliação (`last_review`) e uma data de referência (ou a data da primeira avaliação, se disponível). Isso pode indicar a longevidade e experiência do anfitrião na plataforma.

In [ ]:
```
# Calcule a data mais recente de `last_review`
df["last_review"] = pd.to_datetime(df["last_review"], errors="coerce")
# Crie a nova feature `host_experience_days` calculando a diferença em
dias entre a data mais recente e `last_review`
data_mais_recente = df["last_review"].max()
df["host_experience_days"] = (data_mais_recente -
df["last_review"]).dt.days
# Exiba as estatísticas descritivas da nova feature
print(df["host_experience_days"].describe())
```

```
count    35103.000000
mean       914.258810
std       1302.376515
min          0.000000
25%         22.000000
50%        190.000000
75%       1153.000000
max       3475.000000
Name: host_experience_days, dtype: float64
```

7.2) `price_per_night_per_review`

Esta feature pode indicar o custo-benefício percebido, relacionando o preço por noite com o número de avaliações. Um valor baixo pode indicar um bom negócio, enquanto um valor alto pode sugerir um preço elevado para poucos reviews.

In [21]:
```
# Crie a nova feature `price_per_night_per_review`, dividindo `price`
por `number_of_reviews`
df["price_per_night_per_review"] = df["price"] /
df["number_of_reviews"].replace(0, 1)
# Lembre-se de tratar a divisão por zero (e.g., se `number_of_reviews`
for 0, use o próprio `price`)
# Exiba as estatísticas descritivas da nova feature
print(df["price_per_night_per_review"].describe())
```

```
count    35103.000000
mean        50.063416
std         63.828276
min          0.000000
25%          5.852003
50%         22.000000
75%         70.000000
max        333.000000
Name: price_per_night_per_review, dtype: float64
```

8) Análise de Correlação

A correlação mede a força e a direção da relação linear entre duas variáveis numéricas. Um mapa de calor (heatmap) da matriz de correlação é uma excelente ferramenta para visualizar essas relações.

In [22]:

```
# Selecione apenas as colunas numéricas do DataFrame
# Calcule a matriz de correlação
# Crie um heatmap da matriz de correlação usando `sns.heatmap`
# Adicione anotações e um mapa de cores adequado
# Adicione um título ao gráfico
numericas = df.select_dtypes(include=["int64","float64"])
corr_matrix = numericas.corr()

plt.figure(figsize=(12, 6))
sns.heatmap(
    corr_matrix,
    annot=True,
    fmt=".2f",
    cmap="coolwarm",
    cbar=True
)
plt.title("Heatmap da Matriz de Correlacao das variaveis numericas",
fontsize=16)
plt.tight_layout()
plt.show()
```

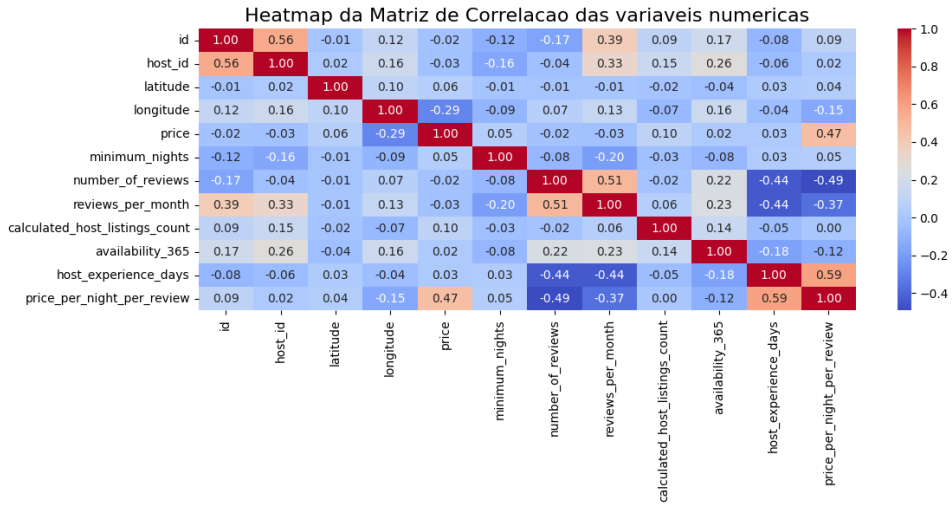

Exported with runcell — convert notebooks to HTML or PDF anytime at runcell.dev.