# Aula 4 — EDA Profissional (Versão Avançada) - Para Aula

Dataset: Kaggle 2024

## Objetivos Desta Aula

- **Dominar os pacotes base do tidyverse** (tibble e stringr) e **entender** os conceitos de dados tidy.
- **Aplicar** tipagem e conversão de dados (factors, datas, numéricos) para **preparar** a base para análise.
- **Realizar análise por categoria e por localização** (bairros/grupos) usando **n** e **proporções** em relatórios **legíveis**.
- **Criação gráfica profissional e interativa:** Utilizar bibliotecas avançadas para visualizações de alta qualidade.
- **Análise Exploratória de Dados (EDA):** Aplicar técnicas de EDA para identificar padrões e insights.
- **Engenharia de Features:** Criar novas variáveis para enriquecer a análise.
- **Análise Geoespacial:** Visualizar dados em um contexto geográfico.
- **Preparação e exercício inicial:** Preparar conclusões significativas dos dados.

## 1) Importação das Bibliotecas Essenciais

Nesta aula, vamos usar, maximizar e dar ênfase ao Exploratory Data Analysis (EDA) e Engenharia de Dados (EDA).

- `janitor`: Para normalizar e limpar os dados em formato de Data Frame.
- `ggplot2`: Para criar gráficos de alta qualidade.
- `ggrepel`: Essencial no ggplot2, ajuda a evitar que os rótulos de texto se sobrepõem em seus gráficos estáticos.
- `scales`: Para operações numéricas e estatísticas, especialmente útil para dar um ajuste ao eixo e rótulos estatísticos.
- `ggthemes`: Para um maior número de temas e escalas para ggplot2.

```
# ==========================================
# 1. IMPORTAÇÃO DE BIBLIOTECAS ESSENCIAIS
# ==========================================
# Carregando o tidyverse (inclui ggplot2, dplyr, tibble, stringr, etc.)
library(tidyverse)
# Para um processamento de dados mais rápido e limpo
library(janitor)
# Para rótulos de gráficos inteligentes
library(ggrepel)
# Para formatação de eixos e escalas
library(scales)
# Para temas e escalas adicionais para ggplot2
library(ggthemes)
# Para manipulação de datas
library(lubridate)
# Para manipulação de strings
library(stringr)
# Para manipulação de tibbles
library(tibble)
# Para manipulação de fatores (categorias)
library(forcats)
# Para ler arquivos CSV
library(readr)
```

## 2) Carregar o Dataset

Carregamos o dataset de Airbnb NYC e ganhamos uma primeira olhada. Em seguida, vamos ver o dados brutos não tidiados e transformados em um DataFrame do pandas para fácil manipulação.

```
# ==========================================
# 2. CARREGAR O DATASET
# ==========================================
# Carregando o dataset do Airbnb NYC a partir de um arquivo CSV.
# Certifique-se de que o arquivo 'AB_NYC_2019.csv' está no seu diretório de trabalho.
# Se não, você precisará mudar o caminho para o arquivo.
df_airbnb <- read_csv("AB_NYC_2019.csv")

# Exibindo as primeiras 6 linhas do dataset para uma visão rápida.
head(df_airbnb)

# Exibindo a estrutura do dataset, mostrando o tipo de cada coluna e alguns dados.
glimpse(df_airbnb)

# Exibindo um resumo estatístico das colunas numéricas.
summary(df_airbnb)
```

```
Rows: 48,895 Columns: 16
── Column specification ────────────────────────────────────────────────────────
Delimiter: ","
chr  (6): name, host_name, neighbourhood_group, neighbourhood, room_type, last_review
dbl  (9): id, host_id, latitude, longitude, price, minimum_nights, number_of_reviews, reviews_per_month, calculated_host_listings_count
dttm (1): last_review

# A tibble: 6 × 16
     id name  host_id host_name neighbourhood_group neighbourhood latitude
  <dbl> <chr>   <dbl> <chr>     <chr>             <chr>          <dbl>
1  2539 Clean…   2787 John      Brooklyn          Kensington      40.65
2  2595 Skyla…   2845 Jennifer  Manhattan         Midtown         40.75
3  3647 THE V…   4632 Elisabeth  Manhattan         Harlem          40.81
4  3831 Cozy E…   5099 LisaRoxanne Brooklyn         Clinton Hill    40.69
5  5022 Entire…   7192 Laura     Manhattan         East Harlem     40.80
6  5099 Large …   7322 Chris     Manhattan         Murray Hill     40.75
  longitude room_type price minimum_nights number_of_reviews last_review
      <dbl> <chr>     <dbl>        <dbl>            <dbl> <dttm>
1     -73.9 Private…   149            1              9 2018-10-19
2     -73.9 Entire …   225            1             45 2019-05-21
3     -73.9 Entire …   150            3             74 2019-07-05
4     -73.9 Private…    89            1             270 2019-07-05
5     -73.9 Entire …   80           10              9 2018-11-19
6     -73.9 Private…   60           45              49 2019-06-22
  reviews_per_month calculated_host_listings_count availability_365
      <dbl>                                   <dbl>             <dbl>
1              0.21                               6               365
2              0.38                               2               355
3              4.64                               1               365
4              4.23                               1               194
5              0.10                               1                 0
6              0.59                               1               129
Rows: 48,895
Columns: 16
$ id                            <dbl> 2539, 2595, 3647, 3831, 5022, 5099, …
$ name                          <chr> "Clean & quiet apt home by the park", …
$ host_id                       <dbl> 2787, 2845, 4632, 5099, 7192, 7322, …
$ host_name                     <chr> "John", "Jennifer", "Elisabeth", "Lis…
$ neighbourhood_group           <chr> "Brooklyn", "Manhattan", "Manhattan", …
$ neighbourhood                 <chr> "Kensington", "Midtown", "Harlem", "C…
$ latitude                      <dbl> 40.64749, 40.75362, 40.80902, 40.68794…
$ longitude                     <dbl> -73.97237, -73.98377, -73.94190, -73.…
$ room_type                     <chr> "Private room", "Entire home/apt", "E…
$ price                         <dbl> 149, 225, 150, 89, 80, 60, 79, 79, 150…
$ minimum_nights                <dbl> 1, 1, 3, 1, 10, 45, 2, 2, 1, 1, 1, 1, …
$ number_of_reviews             <dbl> 9, 45, 74, 270, 9, 49, 430, 118, 160, …
$ last_review                   <dbl> 18171, 18778, 18447, 18447, 18503, 18…
$ reviews_per_month             <dbl> 0.21, 0.38, 4.64, 4.23, 0.10, 0.59, 3…
$ calculated_host_listings_count <dbl> 6, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, …
$ availability_365              <dbl> 365, 355, 365, 194, 0, 129, 188, 192,…
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
```

## 3) Visão Geral e Estrutura dos Dados

Esta seção fornece uma visão geral dos dados do dataset, incluindo suas dimensões, tipos de dados e a um resumo estatístico. Isso nos ajuda a entender a estrutura dos dados e identificar possíveis problemas, como valores ausentes ou tipos de dados incorretos.

```
# ==========================================
# 3. VISÃO GERAL E ESTRUTURA DOS DADOS
# ==========================================
# Exibindo a dimensão do dataset (número de linhas e colunas).
# Isso nos dá uma visão do tamanho do nosso conjunto de dados.
dim(df_airbnb)

# Exibindo a estrutura do dataset, mostrando o tipo de cada coluna e alguns dados.
# Isso é crucial para identificar tipos de dados incorretos.
glimpse(df_airbnb)

# Exibindo um resumo estatístico das colunas numéricas.
# Isso nos dá uma visão rápida da distribuição, valores ausentes (NA) e outliers.
summary(df_airbnb)
```

```
[1] 48895 16
Rows: 48,895
Columns: 16
$ id                            <dbl> 2539, 2595, 3647, 3831, 5022, 5099, …
$ name                          <chr> "Clean & quiet apt home by the park", …
$ host_id                       <dbl> 2787, 2845, 4632, 5099, 7192, 7322, …
$ host_name                     <chr> "John", "Jennifer", "Elisabeth", "Lis…
$ neighbourhood_group           <chr> "Brooklyn", "Manhattan", "Manhattan", …
$ neighbourhood                 <chr> "Kensington", "Midtown", "Harlem", "C…
$ latitude                      <dbl> 40.64749, 40.75362, 40.80902, 40.68794…
$ longitude                     <dbl> -73.97237, -73.98377, -73.94190, -73.…
$ room_type                     <chr> "Private room", "Entire home/apt", "E…
$ price                         <dbl> 149, 225, 150, 89, 80, 60, 79, 79, 150…
$ minimum_nights                <dbl> 1, 1, 3, 1, 10, 45, 2, 2, 1, 1, 1, 1, …
$ number_of_reviews             <dbl> 9, 45, 74, 270, 9, 49, 430, 118, 160, …
$ last_review                   <dbl> 18171, 18778, 18447, 18447, 18503, 18…
$ reviews_per_month             <dbl> 0.21, 0.38, 4.64, 4.23, 0.10, 0.59, 3…
$ calculated_host_listings_count <dbl> 6, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, …
$ availability_365              <dbl> 365, 355, 365, 194, 0, 129, 188, 192,…
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
```

## 4) Tratamento de Valores Faltantes

Valores faltantes são comuns em datasets reais e podem ser um problema para análises. Nesta seção, identificamos e tratamos esses valores, decidindo entre remover, preencher com um valor específico (média, mediana, moda) ou usar métodos mais avançados.

```
# ==========================================
# 4. TRATAMENTO DE VALORES FALTANTES
# ==========================================
# Criando uma cópia do dataset para não alterar o original durante o tratamento.
df_airbnb_clean <- df_airbnb

# Verificando a quantidade de valores ausentes em cada coluna.
# Isso é crucial para decidir como tratar os dados faltantes.
colSums(is.na(df_airbnb_clean))

# Preenchendo valores ausentes em colunas específicas com valores apropriados.
# Para 'last_review', preenchemos com uma data muito antiga.
# Para 'reviews_per_month', preenchemos com 0, pois ausência de avaliação significa 0 avaliações por mês.
df_airbnb_clean$last_review[is.na(df_airbnb_clean$last_review)] <- as.Date("1970-01-01")
df_airbnb_clean$reviews_per_month[is.na(df_airbnb_clean$reviews_per_month)] <- 0

# Verificando se ainda há valores ausentes após o tratamento.
colSums(is.na(df_airbnb_clean))
```

```
id                              name                           host_id                         host_name
                               0                              0                               0                               0
neighbourhood_group             neighbourhood                       latitude                       longitude                       room_type
                               0                              0                               0                               0
price                           minimum_nights                 number_of_reviews               last_review                     reviews_per_month
                               0                              0                               0                               0
calculated_host_listings_count  availability_365
                               0                              0
Warning: Unknown or uninitialised column: 'last_review'.
Warning: Unknown or uninitialised column: 'last_review'.
id                              name                           host_id                         host_name
                               0                              0                               0                               0
neighbourhood_group             neighbourhood                       latitude                       longitude                       room_type
                               0                              0                               0                               0
price                           minimum_nights                 number_of_reviews               last_review                     reviews_per_month
                               0                              0                               0                               0
calculated_host_listings_count  availability_365
                               0                              0
```

## 5) Detecção e Tratamento de Outliers

Outliers são valores que desviam muito da tendência geral dos dados e podem distorcer análises estatísticas e modelos de machine learning. Nesta seção, identificamos e tratamos outliers em variáveis numéricas chave, como preços e quantidade mínima de noites, usando o método do Intervalo Interquartil (IQR).

```
# ==========================================
# 5. DETECÇÃO E TRATAMENTO DE OUTLIERS
# ==========================================
# Criando uma função para calcular os limites inferior e superior para detecção de outliers usando o método IQR.
# Isso é uma forma robusta de identificar valores que se desviam muito da maioria dos dados.
calcular_limites_iqr <- function(coluna, fator = 1.5) {
  # Calcula o primeiro e terceiro quartis da coluna.
  q1 <- quantile(coluna, 0.25, na.rm = TRUE)
  q3 <- quantile(coluna, 0.75, na.rm = TRUE)
  # Calcula o intervalo interquartil.
  iqr <- q3 - q1
  # Retorna o limite inferior e superior.
  limite_inferior <- q1 - fator * iqr
  limite_superior <- q3 + fator * iqr
  return c(limite_inferior, limite_superior)
}

# Aplicando a função para calcular os limites para a coluna 'price'.
limites_price <- calcular_limites_iqr(df_airbnb_clean$price)
print("Limites para preço:")
print(limites_price)

# Criando um boxplot para visualizar os outliers na coluna 'price'.
# Isso ajuda a entender a distribuição e a quantidade de outliers.
ggplot(df_airbnb_clean, aes(y = price)) +
  geom_boxplot(fill = "lightblue", outlier.colour = "red") +
  labs(title = "Boxplot de Preços para Identificar Outliers",
       subtitle = "Pontos vermelhos são considerados outliers pelo método IQR",
       y = "Preço") +
  theme_minimal()

# Criando um boxplot para visualizar os outliers na coluna 'minimum_nights'.
# Isso ajuda a entender a distribuição e a quantidade de outliers.
ggplot(df_airbnb_clean, aes(y = minimum_nights)) +
  geom_boxplot(fill = "lightgreen", outlier.colour = "red") +
  labs(title = "Boxplot de Noites Mínimas para Identificar Outliers",
       subtitle = "Pontos vermelhos são considerados outliers pelo método IQR",
       y = "Noites Mínimas") +
  theme_minimal()

# Criando uma cópia do dataset para remover outliers.
df_airbnb_no_outliers <- df_airbnb_clean

# Removendo outliers da coluna 'price'.
# Mantemos apenas os valores que estão dentro dos limites calculados.
df_airbnb_no_outliers <- df_airbnb_no_outliers[df_airbnb_no_outliers$price >= limites_price[1] &
                               df_airbnb_no_outliers$price <= limites_price[2], ]

# Removendo outliers da coluna 'minimum_nights'.
limites_minimum_nights <- calcular_limites_iqr(df_airbnb_no_outliers$minimum_nights)
df_airbnb_no_outliers <- df_airbnb_no_outliers[df_airbnb_no_outliers$minimum_nights >= limites_minimum_nights[1] &
                               df_airbnb_no_outliers$minimum_nights <= limites_minimum_nights[2], ]

# Exibindo a dimensão do dataset após a remoção de outliers.
# Isso mostra quantas linhas foram removidas.
dim(df_airbnb_no_outliers)
```

```
[1] 0 0
[1] "Limites para preço:"
[1]  -1 1 0 0 0
```