Aula 4 — EDA Profissional (Versão Avançada) - Para Aula

Dataset: Airbnb NYC

Objetivos Desta Aula

- **Explorar um dataset real de mercado:** Entender a estrutura e o conteúdo de dados reais.
- **Detectar e tratar valores faltantes e outliers:** Aprender técnicas para limpar e preparar os dados.
- **Realizar análise por categoria e por localização:** Investigar padrões e tendências em diferentes segmentos e regiões.
- **Construir gráficos profissionais e informativos:** Utilizar bibliotecas avançadas para visualizações de alta qualidade.
- **Introduzir correlação entre variáveis:** Entender as relações entre diferentes atributos do dataset.
- **Engenharia de Features:** Criar novas variáveis para enriquecer a análise.
- **Análise Geoespacial:** Visualizar dados em um contexto geográfico.
- **Interpretar e comunicar insights:** Extrair conclusões significativas dos dados.

1) Importação das bibliotecas Essenciais

Nesta seção, importamos todas as bibliotecas Python necessárias para a Análise Exploratória de Dados (EDA).

- `pandas` : Para manipulação e análise de dados em formato de DataFrame.
- `matplotlib.pyplot` : Para a criação de gráficos estáticos.
- `seaborn` : Baseado no matplotlib, oferece uma interface de alto nível para criar gráficos estatísticos atraentes e informativos.
- `numpy` : Para operações numéricas e matemáticas, especialmente útil para lidar com arrays e cálculos estatísticos.
- `folium` : Para criar mapas interativos e visualizar dados geoespaciais.

In [1]:
```
# Importe aqui as bibliotecas necessárias: pandas, matplotlib.pyplot, seaborn, n
# Configure os estilos de visualização (sns.set_style, plt.rcParams)
%pip install pandas
%pip install seaborn
%pip install numpy
%pip install folium
%pip install matplotlib

import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns
```

```python
import folium as folium

sns.set_style('darkgrid')
plt.rcParams.update({
    'figure.figsize' : (12,6),
    'figure.dpi': 100,
    'axes.titlesize': 18,
    'axes.labelsize': 16,
    'axes.spines.top': False,
    'axes.spines.right': False,
    'grid.alpha': 0.3,
})
```

```
Requirement already satisfied: pandas in c:\users\tomas\anaconda3\lib\site-packag
es (2.3.3)
Requirement already satisfied: numpy>=1.26.0 in c:\users\tomas\anaconda3\lib\site
-packages (from pandas) (2.3.5)
Requirement already satisfied: python-dateutil>=2.8.2 in c:\users\tomas\anaconda3
\lib\site-packages (from pandas) (2.9.0.post0)
Requirement already satisfied: pytz>=2020.1 in c:\users\tomas\anaconda3\lib\site-
packages (from pandas) (2025.2)
Requirement already satisfied: tzdata>=2022.7 in c:\users\tomas\anaconda3\lib\sit
e-packages (from pandas) (2025.2)
Requirement already satisfied: six>=1.5 in c:\users\tomas\anaconda3\lib\site-pack
ages (from python-dateutil>=2.8.2->pandas) (1.17.0)
Note: you may need to restart the kernel to use updated packages.
Requirement already satisfied: seaborn in c:\users\tomas\anaconda3\lib\site-packa
ges (0.13.2)
Requirement already satisfied: numpy!=1.24.0,>=1.20 in c:\users\tomas\anaconda3\l
ib\site-packages (from seaborn) (2.3.5)
Requirement already satisfied: pandas>=1.2 in c:\users\tomas\anaconda3\lib\site-p
ackages (from seaborn) (2.3.3)
Requirement already satisfied: matplotlib!=3.6.1,>=3.4 in c:\users\tomas\anaconda
3\lib\site-packages (from seaborn) (3.10.6)
Requirement already satisfied: contourpy>=1.0.1 in c:\users\tomas\anaconda3\lib\s
ite-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (1.3.3)
Requirement already satisfied: cycler>=0.10 in c:\users\tomas\anaconda3\lib\site-
packages (from matplotlib!=3.6.1,>=3.4->seaborn) (0.11.0)
Requirement already satisfied: fonttools>=4.22.0 in c:\users\tomas\anaconda3\lib
\site-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (4.60.1)
Requirement already satisfied: kiwisolver>=1.3.1 in c:\users\tomas\anaconda3\lib
\site-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (1.4.9)
Requirement already satisfied: packaging>=20.0 in c:\users\tomas\anaconda3\lib\si
te-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (25.0)
Requirement already satisfied: pillow>=8 in c:\users\tomas\anaconda3\lib\site-pac
kages (from matplotlib!=3.6.1,>=3.4->seaborn) (12.0.0)
Requirement already satisfied: pyparsing>=2.3.1 in c:\users\tomas\anaconda3\lib\s
ite-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (3.2.5)
Requirement already satisfied: python-dateutil>=2.7 in c:\users\tomas\anaconda3\l
ib\site-packages (from matplotlib!=3.6.1,>=3.4->seaborn) (2.9.0.post0)
Requirement already satisfied: pytz>=2020.1 in c:\users\tomas\anaconda3\lib\site-
packages (from pandas>=1.2->seaborn) (2025.2)
Requirement already satisfied: tzdata>=2022.7 in c:\users\tomas\anaconda3\lib\sit
e-packages (from pandas>=1.2->seaborn) (2025.2)
Requirement already satisfied: six>=1.5 in c:\users\tomas\anaconda3\lib\site-pack
ages (from python-dateutil>=2.7->matplotlib!=3.6.1,>=3.4->seaborn) (1.17.0)
Note: you may need to restart the kernel to use updated packages.
Requirement already satisfied: numpy in c:\users\tomas\anaconda3\lib\site-package
s (2.3.5)
Note: you may need to restart the kernel to use updated packages.
Requirement already satisfied: folium in c:\users\tomas\anaconda3\lib\site-packag
es (0.20.0)
Requirement already satisfied: branca>=0.6.0 in c:\users\tomas\anaconda3\lib\site
-packages (from folium) (0.8.2)
Requirement already satisfied: jinja2>=2.9 in c:\users\tomas\anaconda3\lib\site-p
ackages (from folium) (3.1.6)
Requirement already satisfied: numpy in c:\users\tomas\anaconda3\lib\site-package
s (from folium) (2.3.5)
Requirement already satisfied: requests in c:\users\tomas\anaconda3\lib\site-pack
ages (from folium) (2.32.5)
Requirement already satisfied: xyzservices in c:\users\tomas\anaconda3\lib\site-p
ackages (from folium) (2025.4.0)
Requirement already satisfied: MarkupSafe>=2.0 in c:\users\tomas\anaconda3\lib\si
```

```
te-packages (from jinja2>=2.9->folium) (3.0.2)
Requirement already satisfied: charset_normalizer<4,>=2 in c:\users\tomas\anacond
a3\lib\site-packages (from requests->folium) (3.4.4)
Requirement already satisfied: idna<4,>=2.5 in c:\users\tomas\anaconda3\lib\site-
packages (from requests->folium) (3.11)
Requirement already satisfied: urllib3<3,>=1.21.1 in c:\users\tomas\anaconda3\lib
\site-packages (from requests->folium) (2.5.0)
Requirement already satisfied: certifi>=2017.4.17 in c:\users\tomas\anaconda3\lib
\site-packages (from requests->folium) (2026.1.4)
Note: you may need to restart the kernel to use updated packages.
Requirement already satisfied: matplotlib in c:\users\tomas\anaconda3\lib\site-pa
ckages (3.10.6)
Requirement already satisfied: contourpy>=1.0.1 in c:\users\tomas\anaconda3\lib\s
ite-packages (from matplotlib) (1.3.3)
Requirement already satisfied: cycler>=0.10 in c:\users\tomas\anaconda3\lib\site-
packages (from matplotlib) (0.11.0)
Requirement already satisfied: fonttools>=4.22.0 in c:\users\tomas\anaconda3\lib
\site-packages (from matplotlib) (4.60.1)
Requirement already satisfied: kiwisolver>=1.3.1 in c:\users\tomas\anaconda3\lib
\site-packages (from matplotlib) (1.4.9)
Requirement already satisfied: numpy>=1.23 in c:\users\tomas\anaconda3\lib\site-p
ackages (from matplotlib) (2.3.5)
Requirement already satisfied: packaging>=20.0 in c:\users\tomas\anaconda3\lib\si
te-packages (from matplotlib) (25.0)
Requirement already satisfied: pillow>=8 in c:\users\tomas\anaconda3\lib\site-pac
kages (from matplotlib) (12.0.0)
Requirement already satisfied: pyparsing>=2.3.1 in c:\users\tomas\anaconda3\lib\s
ite-packages (from matplotlib) (3.2.5)
Requirement already satisfied: python-dateutil>=2.7 in c:\users\tomas\anaconda3\l
ib\site-packages (from matplotlib) (2.9.0.post0)
Requirement already satisfied: six>=1.5 in c:\users\tomas\anaconda3\lib\site-pack
ages (from python-dateutil>=2.7->matplotlib) (1.17.0)
Note: you may need to restart the kernel to use updated packages.
```

2) Carregar o Dataset

Carregamos o dataset do Airbnb NYC a partir de um arquivo CSV. Este é o primeiro passo para qualquer análise de dados, onde os dados brutos são lidos e transformados em um DataFrame do pandas para fácil manipulação.

In [2]:
```
# Carregue o arquivo CSV "AB_NYC_2019.csv" em um DataFrame do pandas
# Exiba as primeiras linhas do DataFrame para uma visão inicial dos dados

df = pd.read_csv('AB_NYC_2019.csv')
df.head()
```

Out[2]:

	id	name	host_id	host_name	neighbourhood_group	neighbourhood	l
0	2539	Clean & quiet apt home by the park	2787	John	Brooklyn	Kensington	4
1	2595	Skylit Midtown Castle	2845	Jennifer	Manhattan	Midtown	4
2	3647	THE VILLAGE OF HARLEM....NEW YORK !	4632	Elisabeth	Manhattan	Harlem	4
3	3831	Cozy Entire Floor of Brownstone	4869	LisaRoxanne	Brooklyn	Clinton Hill	4
4	5022	Entire Apt: Spacious Studio/Loft by central park	7192	Laura	Manhattan	East Harlem	4

3) Visão Geral e Estrutura dos Dados

Esta seção fornece uma visão geral rápida do dataset, incluindo suas dimensões, tipos de dados e um resumo estatístico. Isso nos ajuda a entender a estrutura dos dados e identificar possíveis problemas, como valores ausentes ou tipos de dados incorretos.

In [12]:

```
# Exiba o número de linhas e colunas do DataFrame (df.shape)
# Exiba informações sobre o DataFrame, incluindo tipos de dados e valores não-nu
# Exiba estatísticas descritivas para as colunas numéricas (df.describe())
# Exiba estatísticas descritivas para todas as colunas (incluindo categóricas) (
df.shape
df.info()
df.describe()
df.describe(include="all")
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7391 entries, 0 to 7390
Data columns (total 16 columns):
 #   Column                          Non-Null Count  Dtype
---  ------                          --------------  -----
 0   id                              7391 non-null   int64
 1   name                            7384 non-null   object
 2   host_id                         7391 non-null   int64
 3   host_name                       7386 non-null   object
 4   neighbourhood_group             7391 non-null   object
 5   neighbourhood                   7391 non-null   object
 6   latitude                        7391 non-null   float64
 7   longitude                       7391 non-null   float64
 8   room_type                       7390 non-null   object
 9   price                           7390 non-null   float64
 10  minimum_nights                  7390 non-null   float64
 11  number_of_reviews               7390 non-null   float64
 12  last_review                     6567 non-null   object
 13  reviews_per_month               6567 non-null   float64
 14  calculated_host_listings_count  7390 non-null   float64
 15  availability_365                7390 non-null   float64
dtypes: float64(8), int64(2), object(6)
memory usage: 924.0+ KB
```

Out[12]:

	id	name	host_id	host_name	neighbourhood_group	neighbo
count	7.391000e+03	7384	7.391000e+03	7386	7391	
unique	NaN	7345	NaN	3020	5	
top	NaN	Loft Suite @ The Box House Hotel	NaN	Michael	Manhattan	Willi
freq	NaN	11	NaN	79	3420	
mean	2.443569e+06	NaN	7.922206e+06	NaN	NaN	
std	1.689463e+06	NaN	7.639974e+06	NaN	NaN	
min	2.539000e+03	NaN	2.571000e+03	NaN	NaN	
25%	8.227680e+05	NaN	1.599930e+06	NaN	NaN	
50%	2.224896e+06	NaN	5.076827e+06	NaN	NaN	
75%	4.032019e+06	NaN	1.198219e+07	NaN	NaN	
max	5.478741e+06	NaN	4.139808e+07	NaN	NaN	

4) Tratamento de Valores Faltantes

Valores faltantes são comuns em datasets reais e podem afetar a qualidade da análise. Nesta seção, identificamos e tratamos esses valores, decidindo entre remover, preencher com um valor específico (média, mediana, moda) ou usar métodos mais avançados.

In [13]:
```
# Calcule e exiba a quantidade de valores faltantes por coluna
# Preencha os valores faltantes nas colunas `name` e `host_name` com "unknown"
# Preencha os valores faltantes na coluna `reviews_per_month` com 0
# Converta a coluna `last_review` para datetime e preencha os valores faltantes
# Verifique novamente os valores faltantes após o tratamento
print("Valores faltantes sao:\n",df.isna().sum())
df["name"] = df["name"].fillna("unknown")
df["host_name"]  = df["host_name"].fillna("unknown")
df["reviews_per_month"] =  df["reviews_per_month"].fillna(0)
df["last_review"] = pd.to_datetime(df["last_review"],errors ="coerce")
df["last_review"] = df["last_review"].fillna(pd.Timestamp("2010-01-01"))
print("Os valores faltantes apos o tratamento sao: \n ",df.isna().sum())
```

```
Valores faltantes sao:
 id                                  0
name                                7
host_id                             0
host_name                           5
neighbourhood_group                 0
neighbourhood                       0
latitude                            0
longitude                           0
room_type                           1
price                               1
minimum_nights                      1
number_of_reviews                   1
last_review                       824
reviews_per_month                 824
calculated_host_listings_count      1
availability_365                    1
dtype: int64
Os valores faltantes apos o tratamento sao:
  id                                0
name                              0
host_id                           0
host_name                         0
neighbourhood_group               0
neighbourhood                     0
latitude                          0
longitude                         0
room_type                         1
price                             1
minimum_nights                    1
number_of_reviews                 1
last_review                       0
reviews_per_month                 0
calculated_host_listings_count    1
availability_365                  1
dtype: int64
```

5) Detecção e Tratamento de Outliers

Outliers são pontos de dados que se desviam significativamente de outras observações. Eles podem distorcer análises estatísticas e modelos de machine learning. Nesta seção, identificamos e tratamos outliers em variáveis numéricas chave, como `price` e

`minimum_nights`. Usaremos o método do Intervalo Interquartil (IQR) para uma abordagem robusta.

In [33]:
```
# Defina uma função `remove_outliers_iqr` para detectar e remover outliers usand
# Aplique a função para tratar outliers nas colunas `price`, `minimum_nights` e
# Exiba as estatísticas descritivas antes e depois do tratamento para cada colun
# Atualize o DataFrame principal com os dados limpos
def remover_outilers_iqr(df, coluna):
    Q1 = df[coluna].quantile(0.25)
    Q3 = df[coluna].quantile(0.75)
    IQR = Q3-Q1

    limite_superior=Q3+1.5 * IQR
    limite_inferior=Q1-1.5 * IQR
    df_filtro = df[(df[coluna] >= limite_inferior) & (df[coluna]<= limite_superi
    return df_filtro

print("Estatisticas antes dos tratamentos dos Outliers: \n")
print(df[['price', 'minimum_nights', 'number_of_reviews']].describe())

colunas_tratar= ['price', 'minimum_nights', 'number_of_reviews']

for col in colunas_tratar:
    df=remover_outilers_iqr(df, col)

print("Estatisticas apos os tratamentos dos Outliers \n")
print(df[['price', 'minimum_nights', 'number_of_reviews']].describe())
```

```
Estatisticas antes dos tratamentos dos Outliers:

             price  minimum_nights  number_of_reviews
count  5036.000000     5036.000000        5036.000000
mean    130.412629        2.979349          35.241461
std      64.991190        1.752391          41.382956
min      16.000000        1.000000           0.000000
25%      79.000000        2.000000           3.000000
50%     120.000000        3.000000          17.000000
75%     175.000000        4.000000          55.000000
max     305.000000        7.000000         156.000000
Estatisticas apos os tratamentos dos Outliers

             price  minimum_nights  number_of_reviews
count  4825.000000     4825.000000        4825.000000
mean    130.687254        3.000207          30.458653
std      65.228465        1.767415          35.207046
min      16.000000        1.000000           0.000000
25%      79.000000        2.000000           3.000000
50%     120.000000        3.000000          15.000000
75%     175.000000        4.000000          49.000000
max     305.000000        7.000000         133.000000
```

6) Análise Exploratória de Dados (EDA) Aprofundada

Com os dados limpos, podemos agora aprofundar nossa análise, explorando as distribuições das variáveis, as relações entre elas e identificando padrões que podem gerar insights valiosos.

6.1) Distribuição de Preços

Vamos visualizar a distribuição dos preços dos aluguéis para entender a faixa de valores e identificar a concentração de preços.

In [47]:
```
# Crie um histograma da coluna `price` usando `sns.histplot`
# Crie um boxplot da coluna `price` usando `sns.boxplot`
# Adicione títulos e rótulos aos gráficos

plt.figure(figsize=(12,5))

plt.subplot(1,2,1)
sns.histplot(df["price"])
plt.title("Distribuição dos preços")
plt.xlabel("Preços")
plt.ylabel("Quantidade")

plt.subplot(1,2,2)
sns.boxplot(y=df["price"])
plt.title("Boxplot dos preços")
plt.ylabel("Preços")

plt.tight_layout()
plt.show()
```

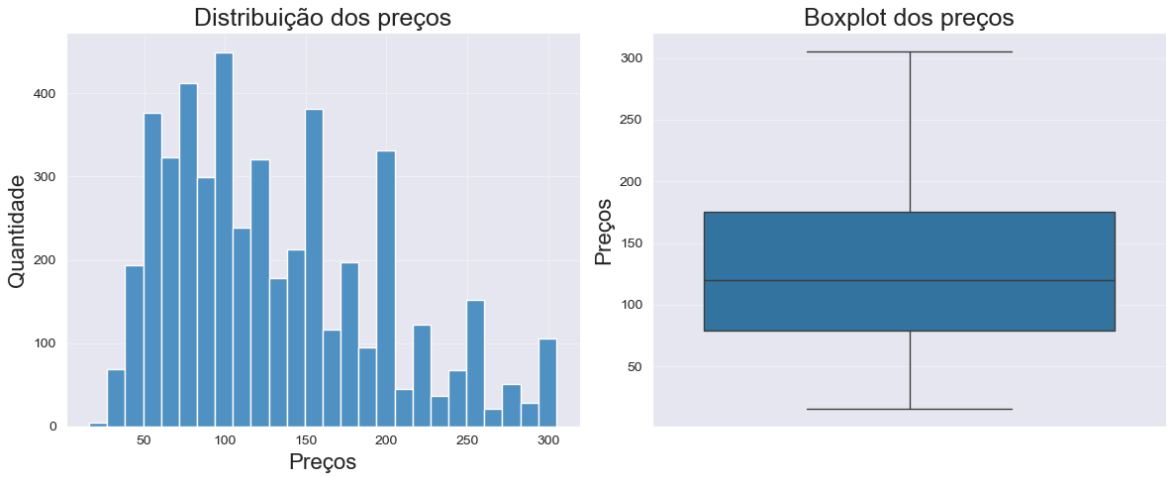

6.2) Análise por Tipo de Quarto (`room_type`)

Entender a distribuição dos tipos de quartos e como eles se relacionam com o preço é crucial para proprietários e hóspedes.

In [51]:
```
# Crie um gráfico de contagem dos tipos de quarto usando `sns.countplot`
# Crie um boxplot do preço por tipo de quarto usando `sns.boxplot`
# Adicione títulos e rótulos aos gráficos
plt.figure(figsize=(12,5))

plt.subplot(1,2,1)
sns.countplot(x="room_type",data=df)
plt.title("Distribuição tipos de quartos")
plt.xlabel("Tipos de Quarto")
plt.ylabel("Quantidade")
```

```
plt.subplot(1,2,2)
sns.boxplot(x="room_type", y="price",data=df)
plt.title("Preços por tipos de quartos")
plt.ylabel("Preços")
plt.xlabel("Tipos de Quarto")

plt.tight_layout()
plt.show()
```

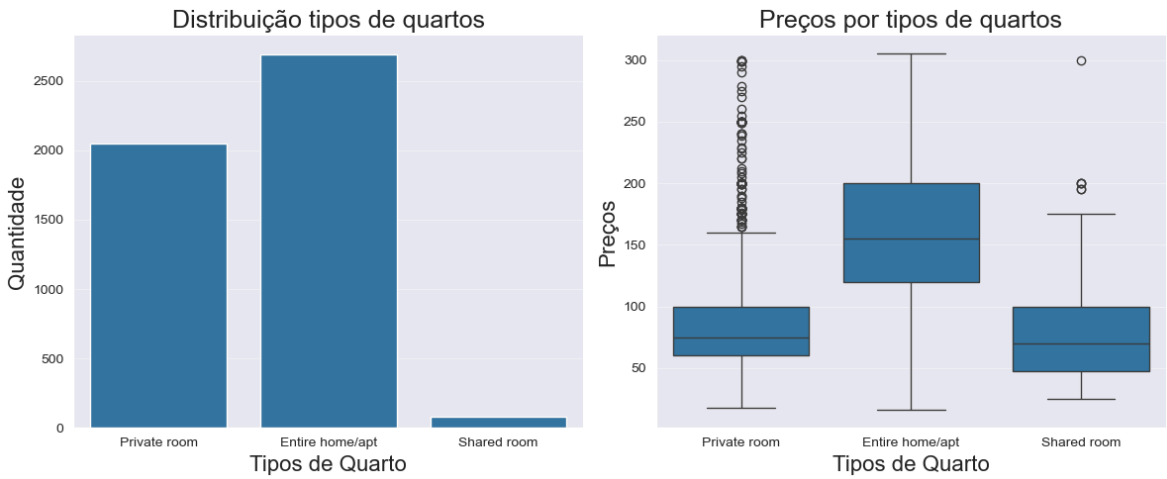

6.3) Análise por Grupo de Bairro (`neighbourhood_group`)

A localização é um dos fatores mais importantes no mercado imobiliário. Vamos analisar como os preços e a disponibilidade variam entre os diferentes grupos de bairros de NYC.

In [52]:
```
# Crie um gráfico de contagem de anúncios por grupo de bairro usando `sns.countp
# Crie um boxplot do preço por grupo de bairro usando `sns.boxplot`
# Adicione títulos e rótulos aos gráficos
plt.figure(figsize=(12,5))

plt.subplot(1,2,1)
sns.countplot(x="neighbourhood_group",data=df)
plt.title("Anuncios por bairro")
plt.xlabel("Grupo de Bairro")
plt.ylabel("Quantidade")

plt.subplot(1,2,2)
sns.boxplot(x="neighbourhood_group", y="price",data=df)
plt.title("Preços por grupo de Bairro")
plt.ylabel("Preços")
plt.xlabel("Grupo de Bairro")

plt.tight_layout()
plt.show()
```

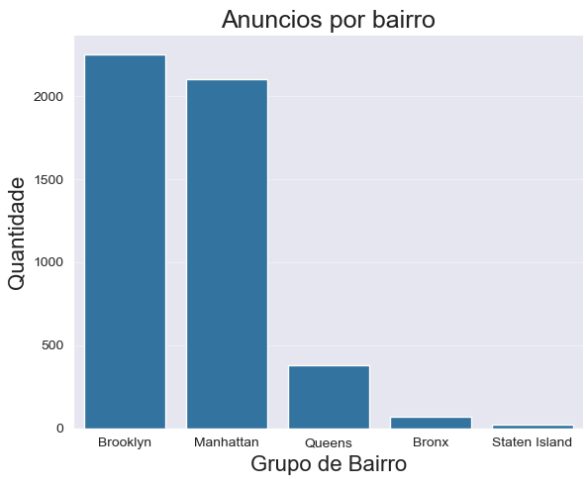

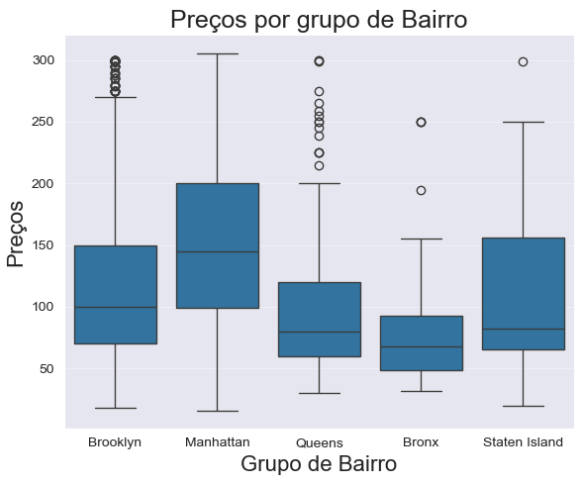

6.4) Top 10 Bairros com Mais Anúncios

Identificar os bairros com maior concentração de anúncios pode indicar áreas de alta demanda ou popularidade.

In [59]:
```
# Calcule os 10 bairros com mais anúncios
# Crie um gráfico de barras para visualizar esses bairros usando `sns.barplot`
# Adicione títulos e rótulos aos gráficos, e rotacione os rótulos do eixo X se n
top10_bairro = df['neighbourhood'].value_counts().head(10).reset_index()
top10_bairro.columns = ['neighbourhood','quantidade']
plt.figure(figsize=(12,5))
sns.barplot(data=top10_bairro,x='neighbourhood',y='quantidade')
plt.title('Bairros com mais anuncios')
plt.xlabel('Bairro')
plt.ylabel('Quantidade de anuncios')
plt.xticks(rotation=45,ha='right')
plt.tight_layout()
plt.show()
```

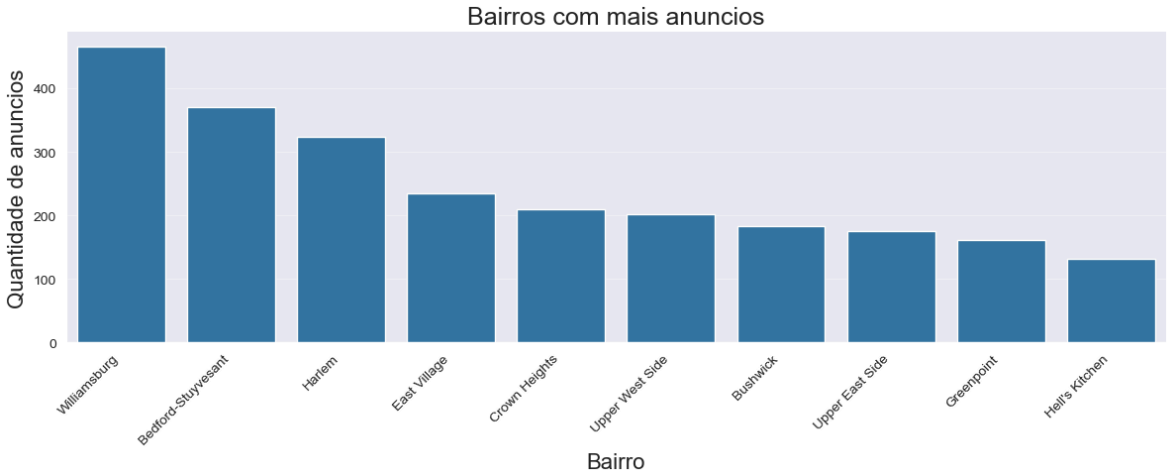

6.5) Análise Geoespacial dos Anúncios

Visualizar os anúncios em um mapa nos permite identificar clusters geográficos e entender a distribuição espacial dos imóveis.

In [68]:
```
# Crie um mapa base de Nova York usando `folium.Map`
# Adicione um `MarkerCluster` ao mapa
```

```python
# Amostre uma parte do DataFrame (e.g., 5000 pontos) para melhor performance na
# Adicione marcadores ao mapa para cada ponto amostrado, incluindo informações n
# Salve o mapa em um arquivo HTML (e.g., "airbnb_nyc_map.html")
# (Opcional) Exiba o mapa diretamente no notebook se o ambiente suportar
from folium.plugins import MarkerCluster
mapa = folium.Map( location=[40.7128, -74.0060],zoom_start=10)
cluster = MarkerCluster()

df_amostra = df.sample(n=3000, random_state=42)

for _,row in df_amostra.iterrows() :
    popup_texto = f"""
    <b>{row['name']}</b><br>
    Bairro: {row['neighbourhood']}<br>
    Tipo: {row['room_type']}<br>
    Preço: R${row['price']}
    """
    folium.Marker(
     location=[row['latitude'],row['longitude']],
     popup=folium.Popup(popup_texto, max_width = 250)
    ).add_to(cluster)
cluster.add_to(mapa)

mapa.save("airbnb_nyc_map.html")

mapa
```

Out[68]:

7) Engenharia de Features

A engenharia de features envolve a criação de novas variáveis a partir das existentes para melhorar a capacidade preditiva dos modelos ou para obter novos insights. Aqui, criaremos algumas features simples.

7.1) `host_experience_days`

Calcularemos a experiência do anfitrião em dias, baseando-nos na data da última avaliação (`last_review`) e uma data de referência (ou a data da primeira avaliação, se disponível). Isso pode indicar a longevidade e experiência do anfitrião na plataforma.

In [3]:
```
# Calcule a data mais recente de `last_review`
# Crie a nova feature `host_experience_days` calculando a diferença em dias entr
# Exiba as estatísticas descritivas da nova feature
df['last_review'] = pd.to_datetime(df['last_review'])

data_recente = df['last_review'].max()

df['host_experience_days'] = (data_recente-df['last_review']).dt.days

print(df['host_experience_days'].describe())
```

```
count    6567.000000
mean      431.956906
std       574.902778
min         0.000000
25%        19.000000
50%        93.000000
75%       750.000000
max      3024.000000
Name: host_experience_days, dtype: float64
```

7.2) `price_per_night_per_review`

Esta feature pode indicar o custo-benefício percebido, relacionando o preço por noite com o número de avaliações. Um valor baixo pode indicar um bom negócio, enquanto um valor alto pode sugerir um preço elevado para poucos reviews.

In [4]:
```
# Crie a nova feature `price_per_night_per_review`, dividindo `price` por `numbe
# Lembre-se de tratar a divisão por zero (e.g., se `number_of_reviews` for 0, us
# Exiba as estatísticas descritivas da nova feature
df['price_per_night_per_review'] = np.where(
    df['number_of_reviews']>0,
    df['price']/df['number_of_reviews'],
    df['price']
)

print(df['price_per_night_per_review'].describe())
```

```
count    7390.000000
mean       52.263063
std       239.643901
min         0.075130
25%         1.685474
50%         7.047118
75%        36.583333
max      9999.000000
Name: price_per_night_per_review, dtype: float64
```

8) Análise de Correlação

A correlação mede a força e a direção da relação linear entre duas variáveis numéricas. Um mapa de calor (heatmap) da matriz de correlação é uma excelente ferramenta para

visualizar essas relações.
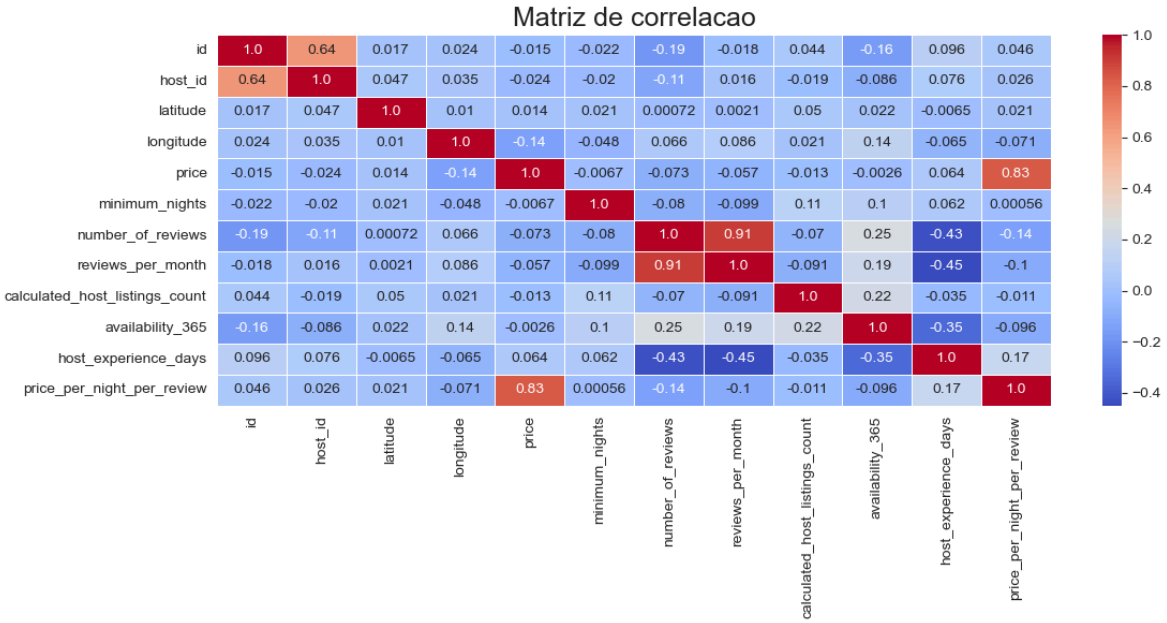
In [7]:
```
# Selecione apenas as colunas numéricas do DataFrame
# Calcule a matriz de correlação
# Crie um heatmap da matriz de correlação usando `sns.heatmap`
# Adicione anotações e um mapa de cores adequado
# Adicione um título ao gráfico

df_numero = df.select_dtypes(include='number')

correlacao = df_numero.corr()

plt.Figure(figsize=(14,10))

sns.heatmap(
    correlacao,
    annot=True,
    fmt='.2',
    cmap='coolwarm',
    linewidths=0.5
)

plt.title('Matriz de correlacao')
plt.tight_layout()
plt.show()
```