Aula 4 — EDA Profissional (Versão Avançada) - Para Aula

Mário Masao Mukai

Dataset: Airbnb NYC

Objetivos Desta Aula

- **Explorar um dataset real de mercado:** Entender a estrutura e o conteúdo de dados reais.
- **Detectar e tratar valores faltantes e outliers:** Aprender técnicas para limpar e preparar os dados.
- **Realizar análise por categoria e por localização:** Investigar padrões e tendências em diferentes segmentos e regiões.
- **Construir gráficos profissionais e informativos:** Utilizar bibliotecas avançadas para visualizações de alta qualidade.
- **Introduzir correlação entre variáveis:** Entender as relações entre diferentes atributos do dataset.
- **Engenharia de Features:** Criar novas variáveis para enriquecer a análise.
- **Análise Geoespacial:** Visualizar dados em um contexto geográfico.
- **Interpretar e comunicar insights:** Extrair conclusões significativas dos dados.

1) Importação das bibliotecas Essenciais

Nesta seção, importamos todas as bibliotecas Python necessárias para a Análise Exploratória de Dados (EDA).

- `pandas`: Para manipulação e análise de dados em formato de DataFrame.
- `matplotlib.pyplot`: Para a criação de gráficos estáticos.
- `seaborn`: Baseado no matplotlib, oferece uma interface de alto nível para criar gráficos estatísticos atraentes e informativos.
- `numpy`: Para operações numéricas e matemáticas, especialmente útil para lidar com arrays e cálculos estatísticos.
- `folium`: Para criar mapas interativos e visualizar dados geoespaciais.

```
# Importe aqui as bibliotecas necessárias: pandas, matplotlib.pyplot,
seaborn, numpy, folium
# Configure os estilos de visualização (sns.set_style, plt.rcParams)
%pip install pandas matplotlib seaborn numpy folium
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
```

```python
import folium
from folium.plugins import MarkerCluster
```

```
Requirement already satisfied: pandas in .\.venv\Lib\site-packages
(3.0.1)
Requirement already satisfied: matplotlib in .\.venv\Lib\site-packages
(3.10.8)
Requirement already satisfied: seaborn in .\.venv\Lib\site-packages
(0.13.2)
Requirement already satisfied: numpy in .\.venv\Lib\site-packages
(2.4.3)
Requirement already satisfied: folium in .\.venv\Lib\site-packages
(0.20.0)
Requirement already satisfied: python-dateutil>=2.8.2 in .\.venv\Lib\
site-packages (from pandas) (2.9.0.post0)
Requirement already satisfied: tzdata in .\.venv\Lib\site-packages
(from pandas) (2025.3)
Requirement already satisfied: contourpy>=1.0.1 in .\.venv\Lib\site-
packages (from matplotlib) (1.3.3)
Requirement already satisfied: cycler>=0.10 in .\.venv\Lib\site-
packages (from matplotlib) (0.12.1)
Requirement already satisfied: fonttools>=4.22.0 in .\.venv\Lib\site-
packages (from matplotlib) (4.62.1)
Requirement already satisfied: kiwisolver>=1.3.1 in .\.venv\Lib\site-
packages (from matplotlib) (1.5.0)
Requirement already satisfied: packaging>=20.0 in .\.venv\Lib\site-
packages (from matplotlib) (26.0)
Requirement already satisfied: pillow>=8 in .\.venv\Lib\site-packages
(from matplotlib) (12.1.1)
Requirement already satisfied: pyparsing>=3 in .\.venv\Lib\site-
packages (from matplotlib) (3.3.2)
Requirement already satisfied: branca>=0.6.0 in .\.venv\Lib\site-
packages (from folium) (0.8.2)
Requirement already satisfied: jinja2>=2.9 in .\.venv\Lib\site-
packages (from folium) (3.1.6)
Requirement already satisfied: requests in .\.venv\Lib\site-packages
(from folium) (2.32.5)
Requirement already satisfied: xyzservices in .\.venv\Lib\site-
packages (from folium) (2025.11.0)
Requirement already satisfied: MarkupSafe>=2.0 in .\.venv\Lib\site-
packages (from jinja2>=2.9->folium) (3.0.3)
Requirement already satisfied: six>=1.5 in .\.venv\Lib\site-packages
(from python-dateutil>=2.8.2->pandas) (1.17.0)
Requirement already satisfied: charset_normalizer<4,>=2 in .\.venv\
Lib\site-packages (from requests->folium) (3.4.6)
Requirement already satisfied: idna<4,>=2.5 in .\.venv\Lib\site-
packages (from requests->folium) (3.11)
Requirement already satisfied: urllib3<3,>=1.21.1 in .\.venv\Lib\site-
packages (from requests->folium) (2.6.3)
Requirement already satisfied: certifi>=2017.4.17 in .\.venv\Lib\site-
```

```
packages (from requests->folium) (2026.2.25)
Note: you may need to restart the kernel to use updated packages.
```

2) Carregar o Dataset

Carregamos o dataset do Airbnb NYC a partir de um arquivo CSV. Este é o primeiro passo para qualquer análise de dados, onde os dados brutos são lidos e transformados em um DataFrame do pandas para fácil manipulação.

```
# Carregue o arquivo CSV "AB_NYC_2019.csv" em um DataFrame do pandas
# Exiba as primeiras linhas do DataFrame para uma visão inicial dos
dados
df = pd.read_csv('AB_NYC_2019.csv')
print(df.head())
```

```
     id                                              name  host_id  \
0  2539                Clean & quiet apt home by the park     2787
1  2595                             Skylit Midtown Castle     2845
2  3647               THE VILLAGE OF HARLEM....NEW YORK !     4632
3  3831                   Cozy Entire Floor of Brownstone     4869
4  5022  Entire Apt: Spacious Studio/Loft by central park     7192

     host_name neighbourhood_group neighbourhood  latitude  longitude
\
0         John            Brooklyn    Kensington  40.64749  -73.97237

1     Jennifer           Manhattan       Midtown  40.75362  -73.98377

2    Elisabeth           Manhattan        Harlem  40.80902  -73.94190

3  LisaRoxanne            Brooklyn  Clinton Hill  40.68514  -73.95976

4        Laura           Manhattan   East Harlem  40.79851  -73.94399


         room_type  price  minimum_nights  number_of_reviews
last_review  \
0     Private room    149               1                  9  2018-10-
19
1  Entire home/apt    225               1                 45  2019-05-
21
2     Private room    150               3                  0
NaN
3  Entire home/apt     89               1                270  2019-07-
05
4  Entire home/apt     80              10                  9  2018-11-
19

   reviews_per_month  calculated_host_listings_count  availability_365
```

```
0                0.21                                 6                365

1                0.38                                 2                355

2                 NaN                                 1                365

3                4.64                                 1                194

4                0.10                                 1                  0
```

3) Visão Geral e Estrutura dos Dados

Esta seção fornece uma visão geral rápida do dataset, incluindo suas dimensões, tipos de dados e um resumo estatístico. Isso nos ajuda a entender a estrutura dos dados e identificar possíveis problemas, como valores ausentes ou tipos de dados incorretos.

```
# Exiba o número de linhas e colunas do DataFrame (df.shape)
# Exiba informações sobre o DataFrame, incluindo tipos de dados e
valores não-nulos (df.info())
# Exiba estatísticas descritivas para as colunas numéricas
(df.describe())
# Exiba estatísticas descritivas para todas as colunas (incluindo
categóricas) (df.describe(include="all"))
print("Dimensões (Linhas, Colunas) =", end = " ")
print(df.shape)
print("\n")
print("Informações gerais:")
df.info()
print("\n")
print("Estatísticas numéricas:")
print(df.describe())
print("\n")
print("Estatísticas gerais:")
print(df.describe(include = "all"))
```

```
Dimensões (Linhas, Colunas) = (48895, 16)


Informações gerais:
<class 'pandas.DataFrame'>
RangeIndex: 48895 entries, 0 to 48894
Data columns (total 16 columns):
 #   Column                          Non-Null Count  Dtype
---  ------                          --------------  -----
 0   id                              48895 non-null  int64
 1   name                            48879 non-null  str
 2   host_id                         48895 non-null  int64
 3   host_name                       48874 non-null  str
 4   neighbourhood_group             48895 non-null  str
```

```
 5   neighbourhood                   48895 non-null  str
 6   latitude                        48895 non-null  float64
 7   longitude                       48895 non-null  float64
 8   room_type                       48895 non-null  str
 9   price                           48895 non-null  int64
 10  minimum_nights                  48895 non-null  int64
 11  number_of_reviews               48895 non-null  int64
 12  last_review                     38843 non-null  str
 13  reviews_per_month               38843 non-null  float64
 14  calculated_host_listings_count  48895 non-null  int64
 15  availability_365                48895 non-null  int64
dtypes: float64(3), int64(7), str(6)
memory usage: 6.0 MB


Estatísticas numéricas:
                 id       host_id      latitude     longitude
price  \
count  4.889500e+04  4.889500e+04  48895.000000  48895.000000
48895.000000
mean   1.901714e+07  6.762001e+07     40.728949    -73.952170
152.720687
std    1.098311e+07  7.861097e+07      0.054530      0.046157
240.154170
min    2.539000e+03  2.438000e+03     40.499790    -74.244420
0.000000
25%    9.471945e+06  7.822033e+06     40.690100    -73.983070
69.000000
50%    1.967728e+07  3.079382e+07     40.723070    -73.955680
106.000000
75%    2.915218e+07  1.074344e+08     40.763115    -73.936275
175.000000
max    3.648724e+07  2.743213e+08     40.913060    -73.712990
10000.000000

       minimum_nights  number_of_reviews  reviews_per_month  \
count    48895.000000       48895.000000       38843.000000
mean         7.029962          23.274466           1.373221
std         20.510550          44.550582           1.680442
min          1.000000           0.000000           0.010000
25%          1.000000           1.000000           0.190000
50%          3.000000           5.000000           0.720000
75%          5.000000          24.000000           2.020000
max       1250.000000         629.000000          58.500000

       calculated_host_listings_count  availability_365
count                    48895.000000      48895.000000
mean                         7.143982        112.781327
std                         32.952519        131.622289
min                          1.000000          0.000000
```

```
25%                          1.000000          0.000000
50%                          1.000000         45.000000
75%                          2.000000        227.000000
max                        327.000000        365.000000


Estatísticas gerais:
                  id            name       host_id host_name  \
count   4.889500e+04           48879  4.889500e+04     48874
unique           NaN           47905           NaN     11452
top              NaN  Hillside Hotel           NaN   Michael
freq             NaN              18           NaN       417
mean    1.901714e+07             NaN  6.762001e+07       NaN
std     1.098311e+07             NaN  7.861097e+07       NaN
min     2.539000e+03             NaN  2.438000e+03       NaN
25%     9.471945e+06             NaN  7.822033e+06       NaN
50%     1.967728e+07             NaN  3.079382e+07       NaN
75%     2.915218e+07             NaN  1.074344e+08       NaN
max     3.648724e+07             NaN  2.743213e+08       NaN

       neighbourhood_group neighbourhood      latitude
longitude  \
count                48895         48895  48895.000000  48895.000000

unique                   5           221           NaN           NaN

top              Manhattan  Williamsburg           NaN           NaN

freq                 21661          3920           NaN           NaN

mean                   NaN           NaN     40.728949    -73.952170

std                    NaN           NaN      0.054530      0.046157

min                    NaN           NaN     40.499790    -74.244420

25%                    NaN           NaN     40.690100    -73.983070

50%                    NaN           NaN     40.723070    -73.955680

75%                    NaN           NaN     40.763115    -73.936275

max                    NaN           NaN     40.913060    -73.712990


               room_type         price  minimum_nights
number_of_reviews  \
count              48895  48895.000000    48895.000000
48895.000000
unique                 3           NaN             NaN
NaN
```

```
top     Entire home/apt           NaN              NaN
NaN
freq              25409           NaN              NaN
NaN
mean                NaN    152.720687         7.029962
23.274466
std                 NaN    240.154170        20.510550
44.550582
min                 NaN      0.000000         1.000000
0.000000
25%                 NaN     69.000000         1.000000
1.000000
50%                 NaN    106.000000         3.000000
5.000000
75%                 NaN    175.000000         5.000000
24.000000
max                 NaN  10000.000000      1250.000000
629.000000

       last_review  reviews_per_month  calculated_host_listings_count
\
count        38843       38843.000000                     48895.000000

unique        1764                NaN                             NaN

top     2019-06-23                NaN                             NaN

freq          1413                NaN                             NaN

mean           NaN           1.373221                        7.143982

std            NaN           1.680442                       32.952519

min            NaN           0.010000                        1.000000

25%            NaN           0.190000                        1.000000

50%            NaN           0.720000                        1.000000

75%            NaN           2.020000                        2.000000

max            NaN          58.500000                      327.000000


        availability_365
count       48895.000000
unique               NaN
top                  NaN
freq                 NaN
mean          112.781327
```

```
std           131.622289
min             0.000000
25%             0.000000
50%            45.000000
75%           227.000000
max           365.000000
```

4) Tratamento de Valores Faltantes

Valores faltantes são comuns em datasets reais e podem afetar a qualidade da análise. Nesta seção, identificamos e tratamos esses valores, decidindo entre remover, preencher com um valor específico (média, mediana, moda) ou usar métodos mais avançados.

```
# Calcule e exiba a quantidade de valores faltantes por coluna
# Preencha os valores faltantes nas colunas `name` e `host_name` com
"unknown"
# Preencha os valores faltantes na coluna `reviews_per_month` com 0
# Converta a coluna `last_review` para datetime e preencha os valores
faltantes com uma data de referência (e.g., "2010-01-01")
# Verifique novamente os valores faltantes após o tratamento
print("Valores faltantes por coluna:")
df.isna().sum()
```

```
Valores faltantes por coluna:

id                                     0
name                                  16
host_id                                0
host_name                             21
neighbourhood_group                    0
neighbourhood                          0
latitude                               0
longitude                              0
room_type                              0
price                                  0
minimum_nights                         0
number_of_reviews                      0
last_review                        10052
reviews_per_month                  10052
calculated_host_listings_count         0
availability_365                       0
dtype: int64
```

```
print("\n")
df["name"] = df["name"].fillna("unknown")
df["host_name"] = df["host_name"].fillna("unknown")
df["reviews_per_month"] = df["reviews_per_month"].fillna(0)
df["last_review"] = pd.to_datetime(df["last_review"])
```

```
df["last_review"] = df["last_review"].fillna("2010-01-01")
print("Valores faltantes por coluna após tratamento:")
df.isna().sum()
```

```
Valores faltantes por coluna após tratamento:

id                                  0
name                                0
host_id                             0
host_name                           0
neighbourhood_group                 0
neighbourhood                       0
latitude                            0
longitude                           0
room_type                           0
price                               0
minimum_nights                      0
number_of_reviews                   0
last_review                         0
reviews_per_month                   0
calculated_host_listings_count      0
availability_365                    0
dtype: int64
```

5) Detecção e Tratamento de Outliers

Outliers são pontos de dados que se desviam significativamente de outras observações. Eles podem distorcer análises estatísticas e modelos de machine learning. Nesta seção, identificamos e tratamos outliers em variáveis numéricas chave, como `price` e `minimum_nights`. Usaremos o método do Intervalo Interquartil (IQR) para uma abordagem robusta.

```
# Defina uma função `remove_outliers_iqr` para detectar e remover
outliers usando o método IQR
# Aplique a função para tratar outliers nas colunas `price`,
`minimum_nights` e `number_of_reviews`
# Exiba as estatísticas descritivas antes e depois do tratamento para
cada coluna
# Atualize o DataFrame principal com os dados limpos
def remove_outliers_iqr (df, column):
    Q1 = df[column].quantile(0.25)
    Q3 = df[column].quantile(0.75)
    iqr = Q3 - Q1
    lower = Q1 - 1.5 * iqr
    upper = Q3 + 1.5 * iqr
    return df[(df[column] >= lower) & (df[column] <= upper)]
```

```
print("Estatísticas antes do tratamento de outliers:")
print(df[["price", "minimum_nights", "number_of_reviews"]].describe())
print("\n")

df = remove_outliers_iqr(df, "price")
df = remove_outliers_iqr(df, "minimum_nights")
df = remove_outliers_iqr(df, "number_of_reviews")

print("Estatísticas após tratamento:")
print(df[["price", "minimum_nights", "number_of_reviews"]].describe())
```

```
Estatísticas antes do tratamento de outliers:
              price  minimum_nights  number_of_reviews
count  48895.000000    48895.000000       48895.000000
mean     152.720687        7.029962          23.274466
std      240.154170       20.510550          44.550582
min        0.000000        1.000000           0.000000
25%       69.000000        1.000000           1.000000
50%      106.000000        3.000000           5.000000
75%      175.000000        5.000000          24.000000
max    10000.000000     1250.000000         629.000000


Estatísticas após tratamento:
              price  minimum_nights  number_of_reviews
count  35202.000000    35202.000000       35202.000000
mean     119.289643        2.765042          12.362536
std       67.831566        1.917473          16.631476
min        0.000000        1.000000           0.000000
25%       65.000000        1.000000           1.000000
50%      100.000000        2.000000           5.000000
75%      155.000000        3.000000          17.000000
max      334.000000       11.000000          71.000000
```

6) Análise Exploratória de Dados (EDA) Aprofundada

Com os dados limpos, podemos agora aprofundar nossa análise, explorando as distribuições das variáveis, as relações entre elas e identificando padrões que podem gerar insights valiosos.

6.1) Distribuição de Preços

Vamos visualizar a distribuição dos preços dos aluguéis para entender a faixa de valores e identificar a concentração de preços.

```
# Crie um histograma da coluna `price` usando `sns.histplot`
# Crie um boxplot da coluna `price` usando `sns.boxplot`
# Adicione títulos e rótulos aos gráficos

fig, (ax_hist, ax_box) = plt.subplots(1, 2, figsize=(14, 5),
```

```
sharex=True)

sns.histplot(df['price'], bins=30, kde=True, color='blue', ax=ax_hist)
ax_hist.set_title('Distribuição de Preços', fontsize=14,
fontweight='bold')
ax_hist.set_xlabel('Preço ($)')
ax_hist.set_ylabel('Frequência')

sns.boxplot(x=df['price'], color='lightcoral', ax=ax_box, width=0.5)
ax_box.set_title('Detecção de Outliers (Boxplot)', fontsize=14,
fontweight='bold')
ax_box.set_xlabel('Preço ($)')
plt.tight_layout()
plt.show()
```

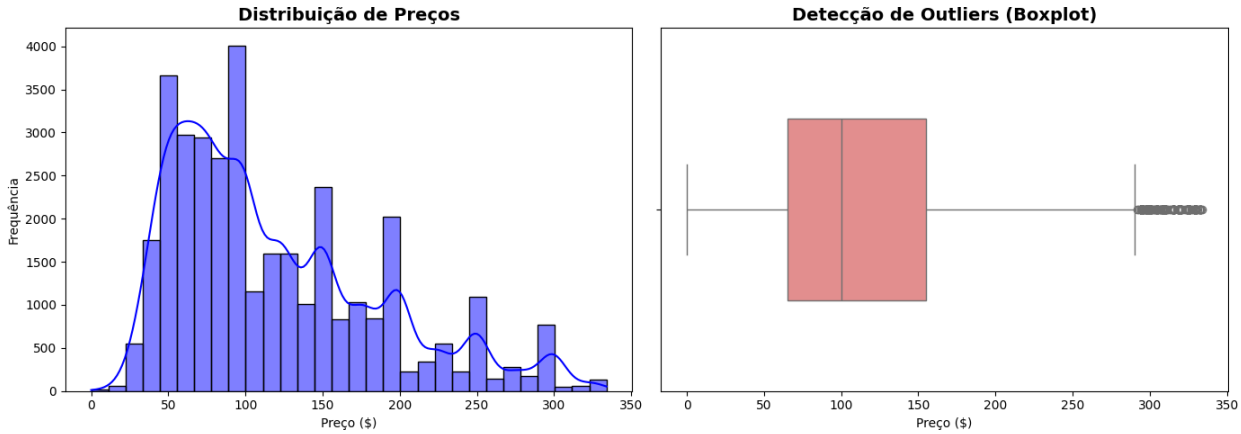

6.2) Análise por Tipo de Quarto (`room_type`)

Entender a distribuição dos tipos de quartos e como eles se relacionam com o preço é crucial para proprietários e hóspedes.

```
# Crie um gráfico de contagem dos tipos de quarto usando
`sns.countplot`
# Crie um boxplot do preço por tipo de quarto usando `sns.boxplot`
# Adicione títulos e rótulos aos gráficos

fig, (ax_count, ax_box) = plt.subplots(1, 2, figsize=(14, 6))

sns.countplot(data=df, x='room_type', palette='viridis',
hue='room_type', legend=False, ax=ax_count)
ax_count.set_title('Popularidade dos Tipos de Quarto', fontsize=14,
fontweight='bold')
ax_count.set_xlabel('Tipo de Quarto')
ax_count.set_ylabel('Quantidade de Anúncios')
ax_count.grid(axis='y', linestyle='--', alpha=0.7)

sns.boxplot(data=df, x='room_type', y='price', palette='Set2',
```

```
hue='room_type', legend=False, ax=ax_box)
ax_box.set_title('Variação de Preço por Categoria', fontsize=14,
fontweight='bold')
ax_box.set_xlabel('Tipo de Quarto')
ax_box.set_ylabel('Preço ($)')
plt.tight_layout()
plt.show()
```

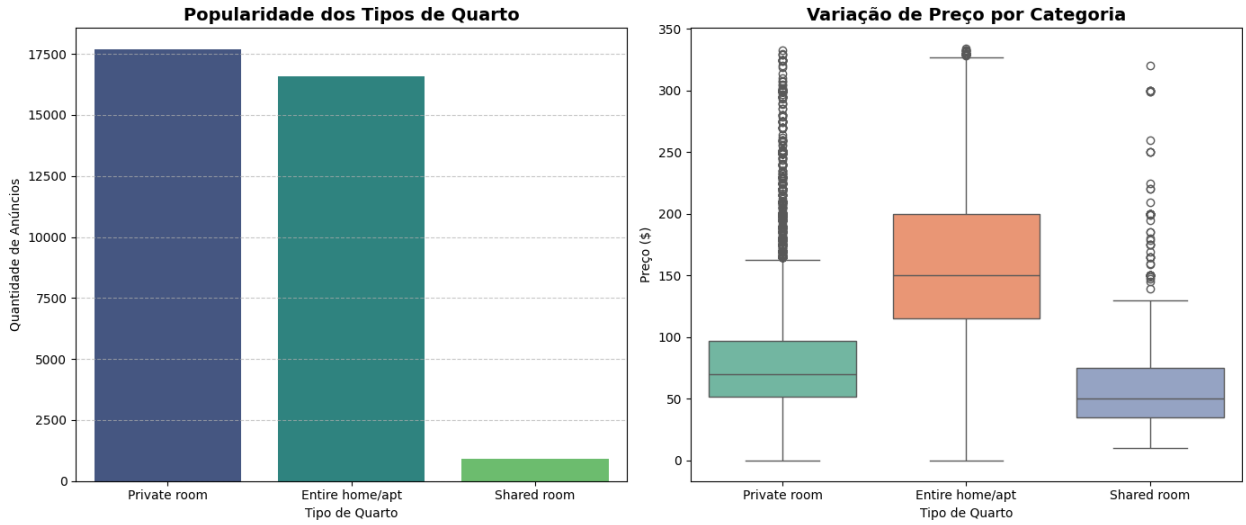

6.3) Análise por Grupo de Bairro (`neighbourhood_group`)

A localização é um dos fatores mais importantes no mercado imobiliário. Vamos analisar como os preços e a disponibilidade variam entre os diferentes grupos de bairros de NYC.

```
# Crie um gráfico de contagem de anúncios por grupo de bairro usando
`sns.countplot`
# Crie um boxplot do preço por grupo de bairro usando `sns.boxplot`
# Adicione títulos e rótulos aos gráficos

fig, (ax_cont, ax_price) = plt.subplots(1, 2, figsize=(16, 6))
order = df['neighbourhood_group'].value_counts().index
sns.countplot(data=df, x='neighbourhood_group', order=order,
palette='magma', hue='neighbourhood_group', legend=False, ax=ax_cont)
ax_cont.set_title('Volume de Anúncios por Região', fontsize=14,
fontweight='bold', pad=15)
ax_cont.set_xlabel('Grupo de Bairro')
ax_cont.set_ylabel('Quantidade Total')
ax_cont.tick_params(axis='x', rotation=45)

sns.boxplot(data=df, x='neighbourhood_group', y='price', order=order,
palette='coolwarm', hue='neighbourhood_group', legend=False,
ax=ax_price)
ax_price.set_title('Distribuição de Preços por Região', fontsize=14,
fontweight='bold', pad=15)
```

```
ax_price.set_xlabel('Grupo de Bairro')
ax_price.set_ylabel('Preço ($)')
ax_price.tick_params(axis='x', rotation=45)
plt.tight_layout()
plt.show()
```

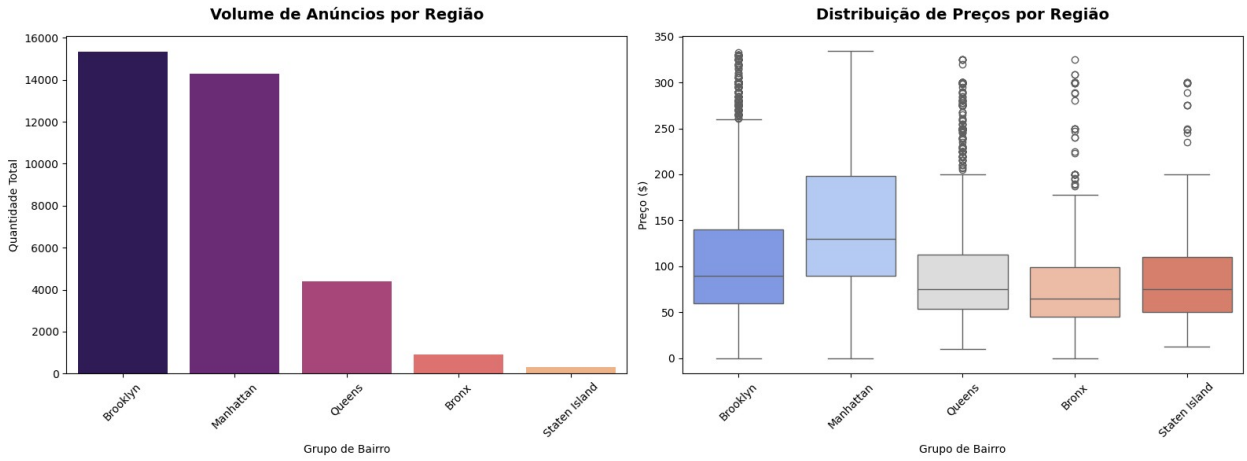

6.4) Top 10 Bairros com Mais Anúncios

Identificar os bairros com maior concentração de anúncios pode indicar áreas de alta demanda ou popularidade.

```
# Calcule os 10 bairros com mais anúncios
# Crie um gráfico de barras para visualizar esses bairros usando
`sns.barplot`
# Adicione títulos e rótulos aos gráficos, e rotacione os rótulos do
eixo X se necessário
top_10 = df['neighbourhood'].value_counts().head(10)
plt.figure(figsize=(10, 5))
sns.barplot(y=top_10.index, x=top_10.values, palette='viridis',
hue=top_10.index, legend=False)

plt.title('Top 10 Bairros com Mais Anúncios')
plt.xlabel('Quantidade de Anúncios')
plt.ylabel('Bairros')
plt.tight_layout()
plt.show()
```

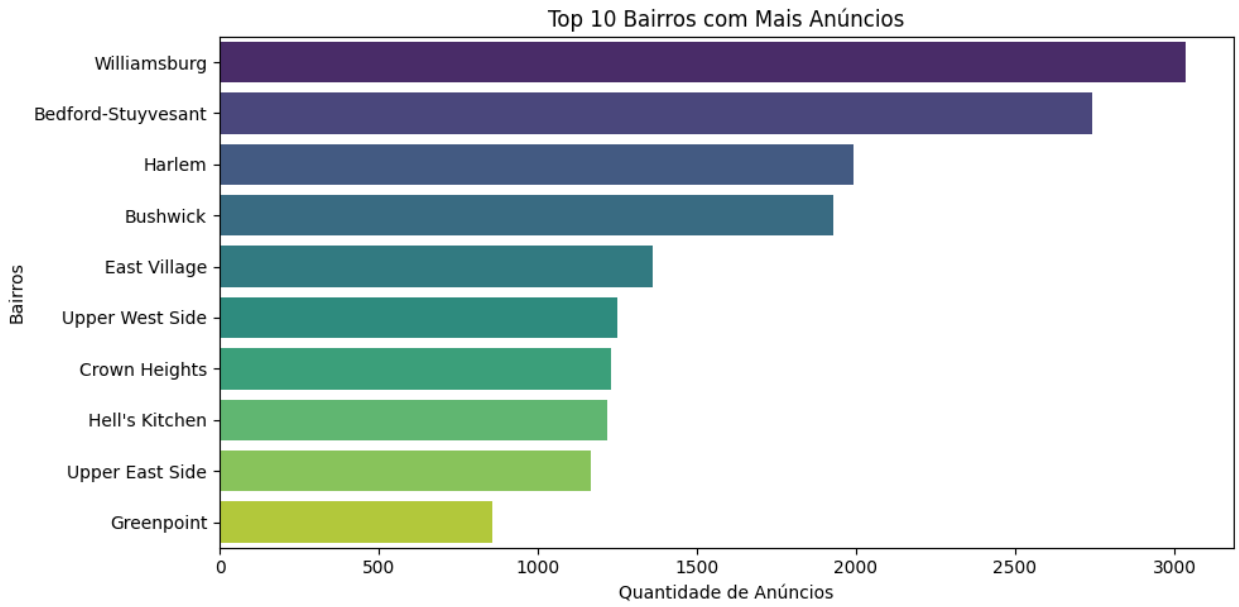

6.5) Análise Geoespacial dos Anúncios

Visualizar os anúncios em um mapa nos permite identificar clusters geográficos e entender a distribuição espacial dos imóveis.

```
# Crie um mapa base de Nova York usando `folium.Map`
# Adicione um `MarkerCluster` ao mapa
# Amostre uma parte do DataFrame (e.g., 5000 pontos) para melhor
performance na visualização
# Adicione marcadores ao mapa para cada ponto amostrado, incluindo
informações no popup
# Salve o mapa em um arquivo HTML (e.g., "airbnb_nyc_map.html")
# (Opcional) Exiba o mapa diretamente no notebook se o ambiente
suportar
mapa_nyc = folium.Map(location=[40.7128, -74.0060], zoom_start=11)
marker_cluster = folium.plugins.MarkerCluster().add_to(mapa_nyc)
amostra = df.sample(n=5000, random_state=42)
for idx, row in amostra.iterrows():
    popup_text = f"Nome: {row['name']}<br>Preço: ${row['price']}"

    folium.Marker(
        location=[row['latitude'], row['longitude']],
        popup=popup_text
    ).add_to(marker_cluster)

mapa_nyc.save("meu_mapa.html")
#Não consegui colocar a imagem, mas gera um html com o mapa
```

7) Engenharia de Features

A engenharia de features envolve a criação de novas variáveis a partir das existentes para melhorar a capacidade preditiva dos modelos ou para obter novos insights. Aqui, criaremos algumas features simples.

7.1) `host_experience_days`

Calcularemos a experiência do anfitrião em dias, baseando-nos na data da última avaliação (`last_review`) e uma data de referência (ou a data da primeira avaliação, se disponível). Isso pode indicar a longevidade e experiência do anfitrião na plataforma.

```
# Calcule a data mais recente de `last_review`
# Crie a nova feature `host_experience_days` calculando a diferença em
dias entre a data mais recente e `last_review`
# Exiba as estatísticas descritivas da nova feature

data_mais_recente = df['last_review'].max()
df['host_experience_days'] = (data_mais_recente -
df['last_review']).dt.days
print(df['host_experience_days'].describe())
```

```
count    35202.000000
mean       912.940032
std       1301.936154
min          0.000000
25%         22.000000
50%        190.000000
75%       1150.000000
max       3475.000000
Name: host_experience_days, dtype: float64
```

7.2) `price_per_night_per_review`

Esta feature pode indicar o custo-benefício percebido, relacionando o preço por noite com o número de avaliações. Um valor baixo pode indicar um bom negócio, enquanto um valor alto pode sugerir um preço elevado para poucos reviews.

```
# Crie a nova feature `price_per_night_per_review`, dividindo `price`
por `number_of_reviews`
# Lembre-se de tratar a divisão por zero (e.g., se `number_of_reviews`
for 0, use o próprio `price`)
# Exiba as estatísticas descritivas da nova feature
df['price_per_night_per_review'] = df['price'] /
df['number_of_reviews'].replace(0, 1)
print(df['price_per_night_per_review'].describe())
```

```
count    35202.000000
mean        49.967902
```

```
std          63.791240
min           0.000000
25%           5.801613
50%          21.966667
75%          70.000000
max         333.000000
Name: price_per_night_per_review, dtype: float64
```

8) Análise de Correlação

A correlação mede a força e a direção da relação linear entre duas variáveis numéricas. Um mapa de calor (heatmap) da matriz de correlação é uma excelente ferramenta para visualizar essas relações.

```
# Selecione apenas as colunas numéricas do DataFrame
# Calcule a matriz de correlação
# Crie um heatmap da matriz de correlação usando `sns.heatmap`
# Adicione anotações e um mapa de cores adequado
# Adicione um título ao gráfico

correlacao = df.select_dtypes('number').corr()
plt.figure(figsize=(10, 8))
sns.heatmap(correlacao, annot=True, cmap='RdBu_r', center=0,
fmt=".2f")

plt.title('Correlação entre as Variáveis')
plt.show()
```

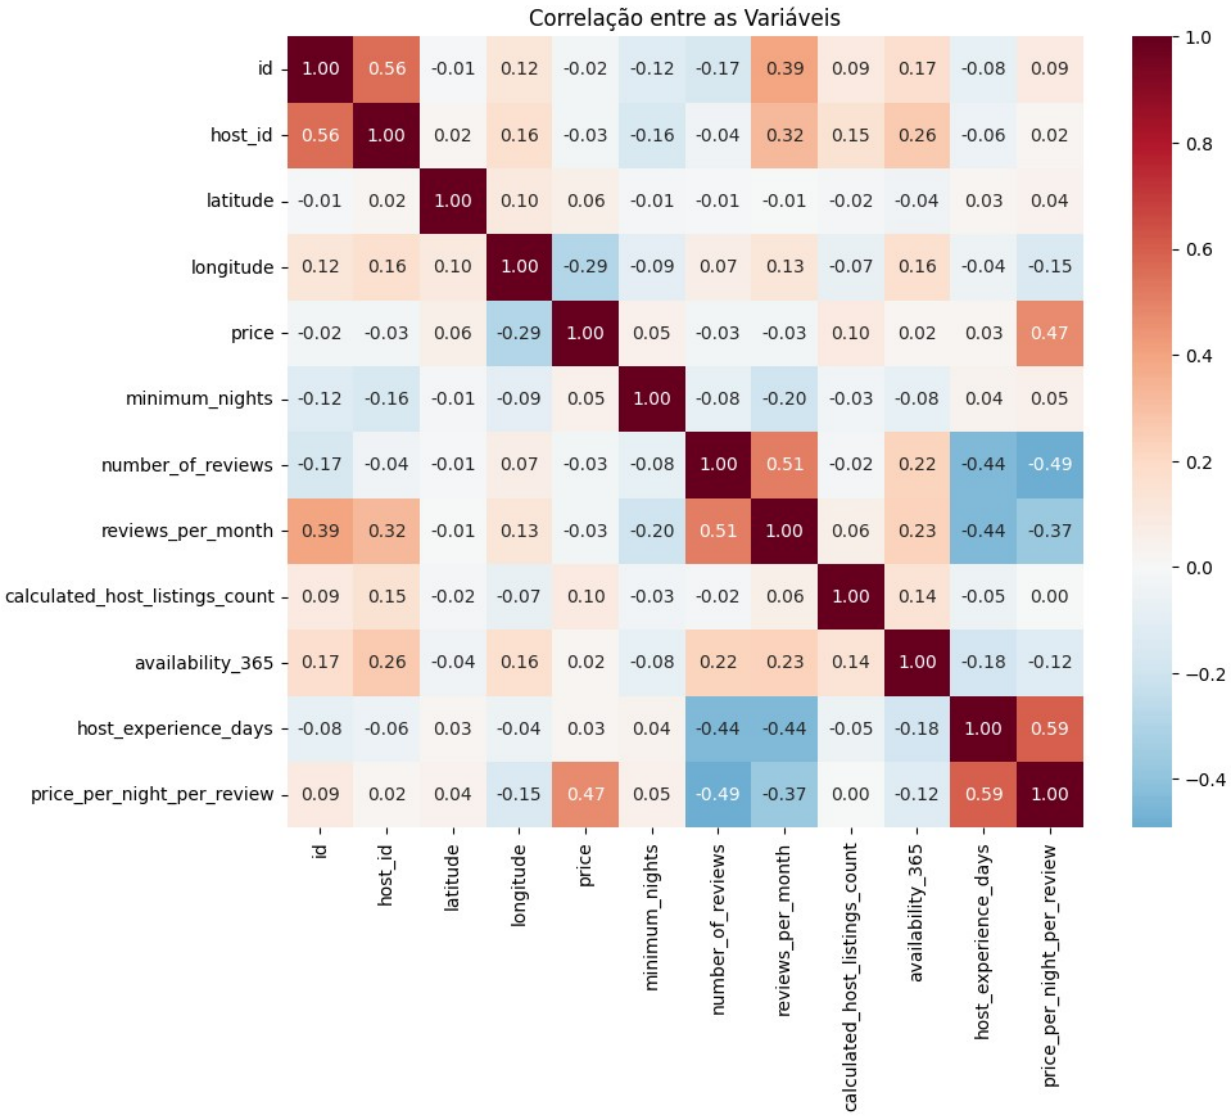
Correlação entre as Variáveis
id 1.00 0.56 -0.01 0.12 -0.02 -0.12 -0.17 0.39 0.09 0.17 -0.08 0.09
host_id 0.56 1.00 0.02 0.16 -0.03 -0.16 -0.04 0.32 0.15 0.26 -0.06 0.02
latitude -0.01 0.02 1.00 0.10 0.06 -0.01 -0.01 -0.01 -0.02 -0.04 0.03 0.04
longitude 0.12 0.16 0.10 1.00 -0.29 -0.09 0.07 0.13 -0.07 0.16 -0.04 -0.15
price -0.02 -0.03 0.06 -0.29 1.00 0.05 -0.03 -0.03 0.10 0.02 0.03 0.47
minimum_nights -0.12 -0.16 -0.01 -0.09 0.05 1.00 -0.08 -0.20 -0.03 -0.08 0.04 0.05
number_of_reviews -0.17 -0.04 -0.01 0.07 -0.03 -0.08 1.00 0.51 -0.02 0.22 -0.44 -0.49
reviews_per_month 0.39 0.32 -0.01 0.13 -0.03 -0.20 0.51 1.00 0.06 0.23 -0.44 -0.37
calculated_host_listings_count 0.09 0.15 -0.02 -0.07 0.10 -0.03 -0.02 0.06 1.00 0.14 -0.05 0.00
availability_365 0.17 0.26 -0.04 0.16 0.02 -0.08 0.22 0.23 0.14 1.00 -0.18 -0.12
host_experience_days -0.08 -0.06 0.03 -0.04 0.03 0.04 -0.44 -0.44 -0.05 -0.18 1.00 0.59
price_per_night_per_review 0.09 0.02 0.04 -0.15 0.47 0.05 -0.49 -0.37 0.00 -0.12 0.59 1.00
id
host_id
latitude
longitude
price
minimum_nights
number_of_reviews
reviews_per_month
calculated_host_listings_count
availability_365
host_experience_days
price_per_night_per_review
1.0
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4