EDA_exercício1

March 19, 2026

1 Aula 4 — EDA Profissional (Versão Avançada) - Para Aula

Dataset: Airbnb NYC

1.1 Objetivos Desta Aula

- **Explorar um dataset real de mercado:** Entender a estrutura e o conteúdo de dados reais.
- **Detectar e tratar valores faltantes e outliers:** Aprender técnicas para limpar e preparar os dados.
- **Realizar análise por categoria e por localização:** Investigar padrões e tendências em diferentes segmentos e regiões.
- **Construir gráficos profissionais e informativos:** Utilizar bibliotecas avançadas para visualizações de alta qualidade.
- **Introduzir correlação entre variáveis:** Entender as relações entre diferentes atributos do dataset.
- **Engenharia de Features:** Criar novas variáveis para enriquecer a análise.
- **Análise Geoespacial:** Visualizar dados em um contexto geográfico.
- **Interpretar e comunicar insights:** Extrair conclusões significativas dos dados.

1.2 1) Importação das bibliotecas Essenciais

Nesta seção, importamos todas as bibliotecas Python necessárias para a Análise Exploratória de Dados (EDA).

- `pandas`: Para manipulação e análise de dados em formato de DataFrame.
- `matplotlib.pyplot`: Para a criação de gráficos estáticos.
- `seaborn`: Baseado no matplotlib, oferece uma interface de alto nível para criar gráficos estatísticos atraentes e informativos.
- `numpy`: Para operações numéricas e matemáticas, especialmente útil para lidar com arrays e cálculos estatísticos.
- `folium`: Para criar mapas interativos e visualizar dados geoespaciais.

[6]:
```
# Importe aqui as bibliotecas necessárias: pandas, matplotlib.pyplot, seaborn,␣
↪numpy, folium
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import folium
```

```
# Configure os estilos de visualização (sns.set_style, plt.rcParams)
sns.set_style("whitegrid")
plt.rcParams["figure.figsize"] = (10, 6)
sns.set_theme()
```

1.3 2) Carregar o Dataset

Carregamos o dataset do Airbnb NYC a partir de um arquivo CSV. Este é o primeiro passo para qualquer análise de dados, onde os dados brutos são lidos e transformados em um DataFrame do pandas para fácil manipulação.

[7]:
```
# Carregue o arquivo CSV "AB_NYC_2019.csv" em um DataFrame do pandas
df = pd.read_csv("AB_NYC_2019.csv")

# Exiba as primeiras linhas do DataFrame para uma visão inicial dos dados
df.head()
```

[7]:
```
     id                                            name  host_id  \
0  2539                Clean & quiet apt home by the park     2787
1  2595                             Skylit Midtown Castle     2845
2  3647               THE VILLAGE OF HARLEM…NEW YORK !     4632
3  3831                    Cozy Entire Floor of Brownstone     4869
4  5022  Entire Apt: Spacious Studio/Loft by central park     7192

     host_name neighbourhood_group neighbourhood  latitude  longitude  \
0         John            Brooklyn    Kensington  40.64749  -73.97237
1     Jennifer           Manhattan       Midtown  40.75362  -73.98377
2    Elisabeth           Manhattan        Harlem  40.80902  -73.94190
3  LisaRoxanne            Brooklyn  Clinton Hill  40.68514  -73.95976
4        Laura           Manhattan   East Harlem  40.79851  -73.94399

         room_type  price  minimum_nights  number_of_reviews last_review  \
0     Private room    149               1                  9  2018-10-19
1  Entire home/apt    225               1                 45  2019-05-21
2     Private room    150               3                  0         NaN
3  Entire home/apt     89               1                270  2019-07-05
4  Entire home/apt     80              10                  9  2018-11-19

   reviews_per_month  calculated_host_listings_count  availability_365
0               0.21                               6               365
1               0.38                               2               355
2                NaN                               1               365
3               4.64                               1               194
4               0.10                               1                 0
```

1.4 3) Visão Geral e Estrutura dos Dados

Esta seção fornece uma visão geral rápida do dataset, incluindo suas dimensões, tipos de dados e um resumo estatístico. Isso nos ajuda a entender a estrutura dos dados e identificar possíveis problemas, como valores ausentes ou tipos de dados incorretos.

[8]:
```
# Exiba o número de linhas e colunas do DataFrame (df.shape)
print(f"O DataFrame tem {df.shape[0]} linhas e {df.shape[1]} colunas.")
print("\n")

# Exiba informações sobre o DataFrame, incluindo tipos de dados e valores␣
↪não-nulos (df.info())
df.info()
print("\n")

# Exiba estatísticas descritivas para as colunas numéricas (df.describe())
print("Estatísticas descritivas para colunas numéricas:")
print(df.describe())
print("\n")

# Exiba estatísticas descritivas para todas as colunas (incluindo categóricas)␣
↪(df.describe(include="all"))
print("Estatísticas descritivas para todas as colunas:")
print(df.describe(include="all"))
```

```
O DataFrame tem 48895 linhas e 16 colunas.


<class 'pandas.DataFrame'>
RangeIndex: 48895 entries, 0 to 48894
Data columns (total 16 columns):
 #   Column                          Non-Null Count  Dtype
---  ------                          --------------  -----
 0   id                              48895 non-null  int64
 1   name                            48879 non-null  str
 2   host_id                         48895 non-null  int64
 3   host_name                       48874 non-null  str
 4   neighbourhood_group             48895 non-null  str
 5   neighbourhood                   48895 non-null  str
 6   latitude                        48895 non-null  float64
 7   longitude                       48895 non-null  float64
 8   room_type                       48895 non-null  str
 9   price                           48895 non-null  int64
 10  minimum_nights                  48895 non-null  int64
 11  number_of_reviews               48895 non-null  int64
 12  last_review                     38843 non-null  str
 13  reviews_per_month               38843 non-null  float64
 14  calculated_host_listings_count  48895 non-null  int64
```

```
 15  availability_365                48895 non-null  int64
dtypes: float64(3), int64(7), str(6)
memory usage: 6.0 MB


Estatísticas descritivas para colunas numéricas:
                 id       host_id      latitude     longitude         price  \
count  4.889500e+04  4.889500e+04  48895.000000  48895.000000  48895.000000
mean   1.901714e+07  6.762001e+07     40.728949    -73.952170    152.720687
std    1.098311e+07  7.861097e+07      0.054530      0.046157    240.154170
min    2.539000e+03  2.438000e+03     40.499790    -74.244420      0.000000
25%    9.471945e+06  7.822033e+06     40.690100    -73.983070     69.000000
50%    1.967728e+07  3.079382e+07     40.723070    -73.955680    106.000000
75%    2.915218e+07  1.074344e+08     40.763115    -73.936275    175.000000
max    3.648724e+07  2.743213e+08     40.913060    -73.712990  10000.000000

       minimum_nights  number_of_reviews  reviews_per_month  \
count    48895.000000       48895.000000       38843.000000
mean         7.029962          23.274466           1.373221
std         20.510550          44.550582           1.680442
min          1.000000           0.000000           0.010000
25%          1.000000           1.000000           0.190000
50%          3.000000           5.000000           0.720000
75%          5.000000          24.000000           2.020000
max       1250.000000         629.000000          58.500000

       calculated_host_listings_count  availability_365
count                    48895.000000      48895.000000
mean                         7.143982        112.781327
std                         32.952519        131.622289
min                          1.000000          0.000000
25%                          1.000000          0.000000
50%                          1.000000         45.000000
75%                          2.000000        227.000000
max                        327.000000        365.000000


Estatísticas descritivas para todas as colunas:
                  id            name       host_id host_name  \
count   4.889500e+04           48879  4.889500e+04     48874
unique           NaN           47905           NaN     11452
top              NaN  Hillside Hotel           NaN   Michael
freq             NaN              18           NaN       417
mean    1.901714e+07             NaN  6.762001e+07       NaN
std     1.098311e+07             NaN  7.861097e+07       NaN
min     2.539000e+03             NaN  2.438000e+03       NaN
25%     9.471945e+06             NaN  7.822033e+06       NaN
50%     1.967728e+07             NaN  3.079382e+07       NaN
```

75%	2.915218e+07	NaN	1.074344e+08	NaN
max	3.648724e+07	NaN	2.743213e+08	NaN

	neighbourhood_group	neighbourhood	latitude	longitude	\
count	48895	48895	48895.000000	48895.000000	
unique	5	221	NaN	NaN	
top	Manhattan	Williamsburg	NaN	NaN	
freq	21661	3920	NaN	NaN	
mean	NaN	NaN	40.728949	-73.952170	
std	NaN	NaN	0.054530	0.046157	
min	NaN	NaN	40.499790	-74.244420	
25%	NaN	NaN	40.690100	-73.983070	
50%	NaN	NaN	40.723070	-73.955680	
75%	NaN	NaN	40.763115	-73.936275	
max	NaN	NaN	40.913060	-73.712990	

	room_type	price	minimum_nights	number_of_reviews	\
count	48895	48895.000000	48895.000000	48895.000000	
unique	3	NaN	NaN	NaN	
top	Entire home/apt	NaN	NaN	NaN	
freq	25409	NaN	NaN	NaN	
mean	NaN	152.720687	7.029962	23.274466	
std	NaN	240.154170	20.510550	44.550582	
min	NaN	0.000000	1.000000	0.000000	
25%	NaN	69.000000	1.000000	1.000000	
50%	NaN	106.000000	3.000000	5.000000	
75%	NaN	175.000000	5.000000	24.000000	
max	NaN	10000.000000	1250.000000	629.000000	

	last_review	reviews_per_month	calculated_host_listings_count	\
count	38843	38843.000000	48895.000000	
unique	1764	NaN	NaN	
top	2019-06-23	NaN	NaN	
freq	1413	NaN	NaN	
mean	NaN	1.373221	7.143982	
std	NaN	1.680442	32.952519	
min	NaN	0.010000	1.000000	
25%	NaN	0.190000	1.000000	
50%	NaN	0.720000	1.000000	
75%	NaN	2.020000	2.000000	
max	NaN	58.500000	327.000000	

	availability_365
count	48895.000000
unique	NaN
top	NaN
freq	NaN
mean	112.781327

```
std           131.622289
min             0.000000
25%             0.000000
50%            45.000000
75%           227.000000
max           365.000000
```

1.5 4) Tratamento de Valores Faltantes

Valores faltantes são comuns em datasets reais e podem afetar a qualidade da análise. Nesta seção, identificamos e tratamos esses valores, decidindo entre remover, preencher com um valor específico (média, mediana, moda) ou usar métodos mais avançados.

[9]:
```python
# Calcule e exiba a quantidade de valores faltantes por coluna
df.isnull().sum()
```

[9]:
```
id                                  0
name                               16
host_id                             0
host_name                          21
neighbourhood_group                 0
neighbourhood                       0
latitude                            0
longitude                           0
room_type                           0
price                               0
minimum_nights                      0
number_of_reviews                   0
last_review                     10052
reviews_per_month               10052
calculated_host_listings_count      0
availability_365                    0
dtype: int64
```

[10]:
```python
# Preencha os valores faltantes nas colunas `name` e `host_name` com "unknown"
df["name"] = df["name"].fillna("unknown")
df["host_name"] = df["host_name"].fillna("unknown")

# Preencha os valores faltantes na coluna `reviews_per_month` com 0
df["reviews_per_month"] = df["reviews_per_month"].fillna(0)

# Converta a coluna `last_review` para datetime e preencha os valores faltantes␣
↪com uma data de referência (e.g., "2010-01-01")
df["last_review"] = pd.to_datetime(df["last_review"])
df["last_review"] = df["last_review"].fillna("2010-01-01")

# Verifique novamente os valores faltantes após o tratamento
df.isnull().sum()
```

[10]:
```
id                                0
name                              0
host_id                           0
host_name                         0
neighbourhood_group               0
neighbourhood                     0
latitude                          0
longitude                         0
room_type                         0
price                             0
minimum_nights                    0
number_of_reviews                 0
last_review                       0
reviews_per_month                 0
calculated_host_listings_count    0
availability_365                  0
dtype: int64
```

1.6 5) Detecção e Tratamento de Outliers

Outliers são pontos de dados que se desviam significativamente de outras observações. Eles podem distorcer análises estatísticas e modelos de machine learning. Nesta seção, identificamos e tratamos outliers em variáveis numéricas chave, como `price` e `minimum_nights`. Usaremos o método do Intervalo Interquartil (IQR) para uma abordagem robusta.

[11]:
```
# Defina uma função `remove_outliers_iqr` para detectar e remover outliers␣
↪usando o método IQR
def remove_outliers_iqr(df, column):
    Q1 = df[column].quantile(0.25)
    Q3 = df[column].quantile(0.75)
    IQR = Q3 - Q1

    limite_inferior = Q1 - 1.5 * IQR
    limite_superior = Q3 + 1.5 * IQR

    df_filtrado = df[(df[column] >= limite_inferior) & (df[column] <=␣
↪limite_superior)]

    return df_filtrado

print("Estatísticas descritivas antes do tratamento de outliers:")
print(df[["price", "minimum_nights", "number_of_reviews"]].describe(), "\n")

# Aplique a função para tratar outliers nas colunas `price`, `minimum_nights` e␣
↪`number_of_reviews`
df = remove_outliers_iqr(df, "price")
df = remove_outliers_iqr(df, "minimum_nights")
```

```
df = remove_outliers_iqr(df, "number_of_reviews")

# Exiba as estatísticas descritivas antes e depois do tratamento para cada␣
↪coluna
print("Estatísticas descritivas após o tratamento de outliers:")
print(df[["price", "minimum_nights", "number_of_reviews"]].describe(), "\n")

# Atualize o DataFrame principal com os dados limpos
```

```
Estatísticas descritivas antes do tratamento de outliers:
              price  minimum_nights  number_of_reviews
count  48895.000000    48895.000000       48895.000000
mean     152.720687        7.029962          23.274466
std      240.154170       20.510550          44.550582
min        0.000000        1.000000           0.000000
25%       69.000000        1.000000           1.000000
50%      106.000000        3.000000           5.000000
75%      175.000000        5.000000          24.000000
max    10000.000000     1250.000000         629.000000

Estatísticas descritivas após o tratamento de outliers:
              price  minimum_nights  number_of_reviews
count  35202.000000    35202.000000       35202.000000
mean     119.289643        2.765042          12.362536
std       67.831566        1.917473          16.631476
min        0.000000        1.000000           0.000000
25%       65.000000        1.000000           1.000000
50%      100.000000        2.000000           5.000000
75%      155.000000        3.000000          17.000000
max      334.000000       11.000000          71.000000
```

1.7 6) Análise Exploratória de Dados (EDA) Aprofundada

Com os dados limpos, podemos agora aprofundar nossa análise, explorando as distribuições das variáveis, as relações entre elas e identificando padrões que podem gerar insights valiosos.

1.7.1 6.1) Distribuição de Preços

Vamos visualizar a distribuição dos preços dos aluguéis para entender a faixa de valores e identificar a concentração de preços.

[12]:
```
# Crie um histograma da coluna `price` usando `sns.histplot`
plt.figure()
sns.histplot(df["price"])
plt.title("Distribuição de Preços")
plt.xlabel("Preço")
plt.ylabel("Frequência")
```

```
plt.show()

# Crie um boxplot da coluna `price` usando `sns.boxplot`
plt.figure()
sns.boxplot(df["price"])
plt.title("Boxplot de Preços")
plt.xlabel("Preço")
plt.show()

# Adicione títulos e rótulos aos gráficos
```

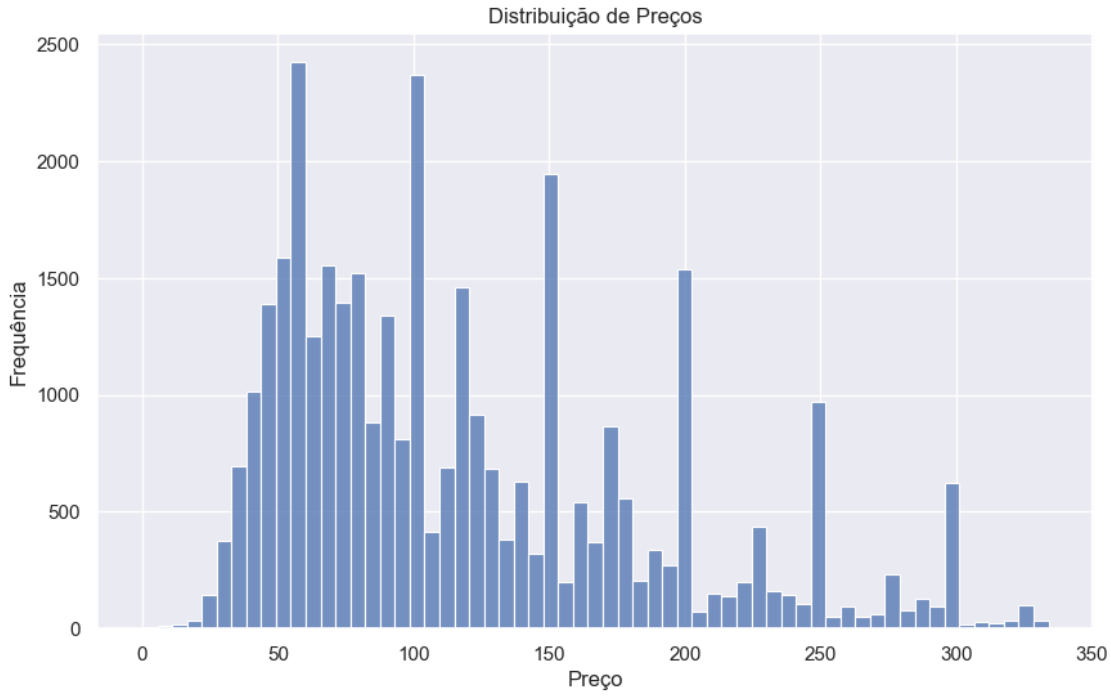

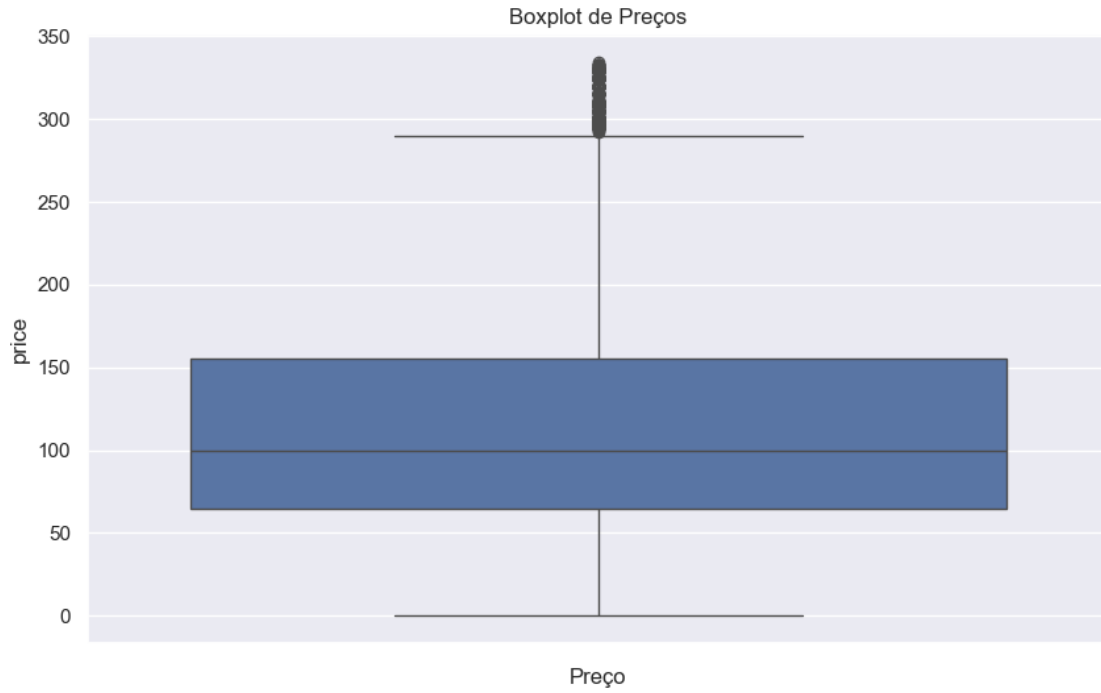

1.7.2 6.2) Análise por Tipo de Quarto (`room_type`)

Entender a distribuição dos tipos de quartos e como eles se relacionam com o preço é crucial para proprietários e hóspedes.

[13]:
```
# Crie um gráfico de contagem dos tipos de quarto usando `sns.countplot`
plt.figure()
sns.countplot(df["room_type"])
plt.title("Contagem por Tipo de Quarto")
plt.xlabel("Tipo de Quarto")
plt.ylabel("Contagem")
plt.show()

# Crie um boxplot do preço por tipo de quarto usando `sns.boxplot`
plt.figure()
sns.boxplot(x="room_type", y="price", data=df)
plt.title("Boxplot de Preços por Tipo de Quarto")
plt.xlabel("Tipo de Quarto")
plt.ylabel("Preço")
plt.show()

# Adicione títulos e rótulos aos gráficos
```

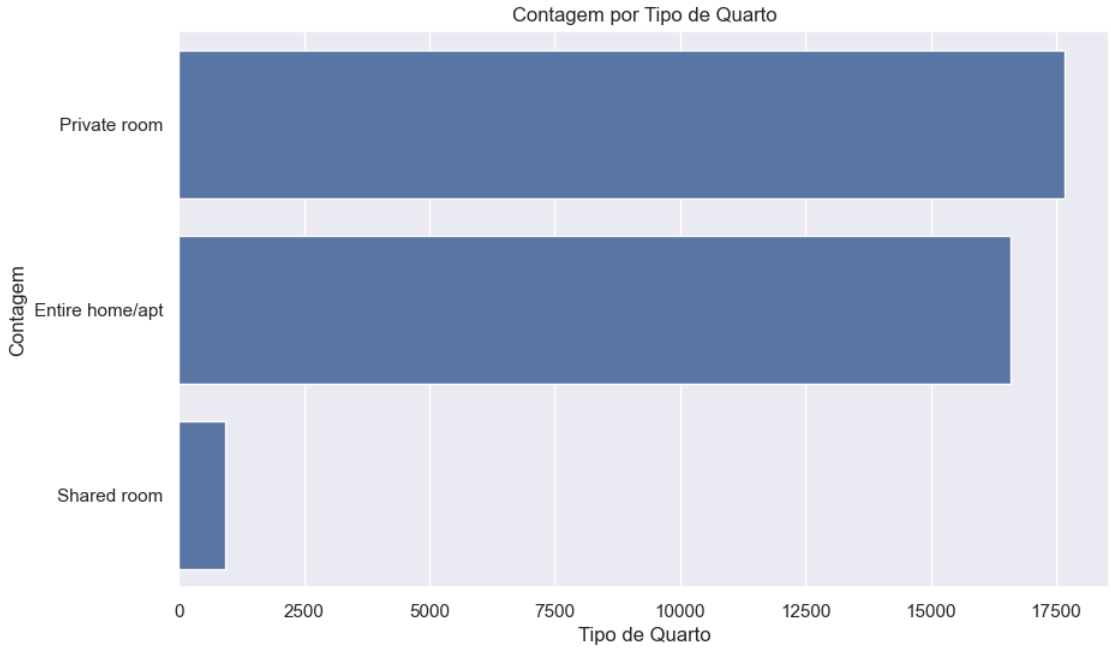
Contagem por Tipo de Quarto
Private room
Entire home/apt
Shared room
Contagem
0
2500
5000
7500
10000
12500
15000
17500
Tipo de Quarto

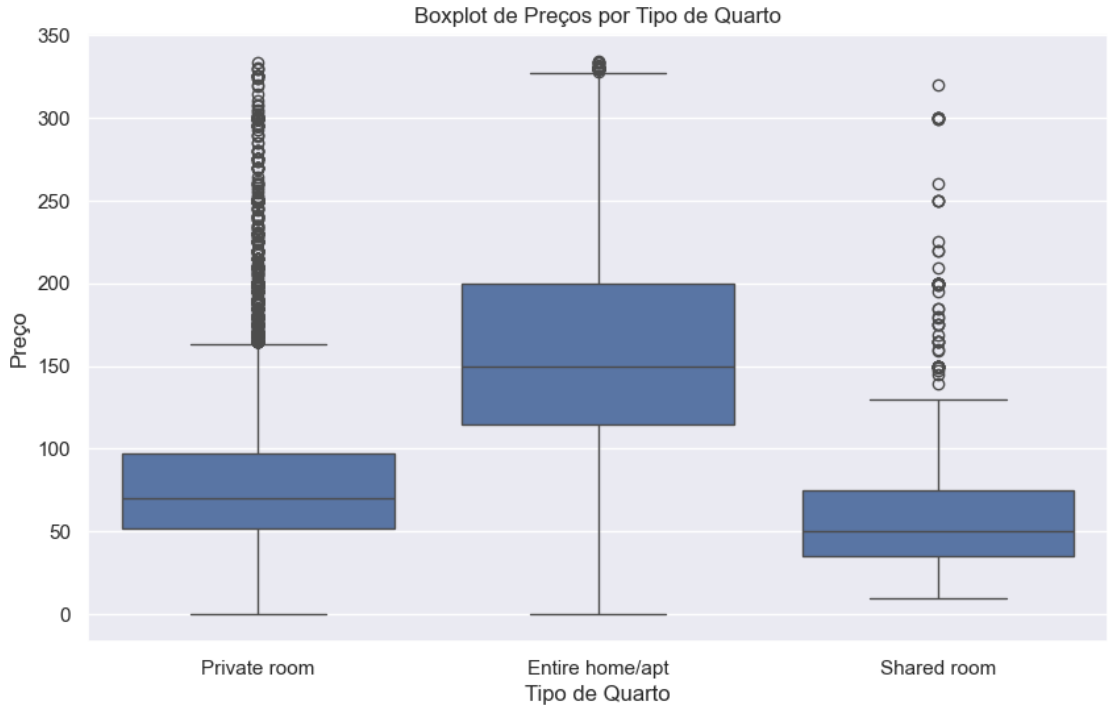
Boxplot de Preços por Tipo de Quarto
350
300
250
200
150
100
50
0
Preço
Private room
Entire home/apt
Shared room
Tipo de Quarto

1.7.3 6.3) Análise por Grupo de Bairro (`neighbourhood_group`)

A localização é um dos fatores mais importantes no mercado imobiliário. Vamos analisar como os preços e a disponibilidade variam entre os diferentes grupos de bairros de NYC.

[14]:
```
# Crie um gráfico de contagem de anúncios por grupo de bairro usando `sns.
↪countplot`
plt.figure()
sns.countplot(df["neighbourhood_group"])
plt.title("Contagem de Anúncios por Grupo de Bairro")
plt.xlabel("Grupo de Bairro")
plt.ylabel("Contagem")
plt.show()

# Crie um boxplot do preço por grupo de bairro usando `sns.boxplot`
plt.figure()
sns.boxplot(x="neighbourhood_group", y="price", data=df)
plt.title("Boxplot de Preços por Grupo de Bairro")
plt.xlabel("Grupo de Bairro")
plt.ylabel("Preço")
plt.show()

# Adicione títulos e rótulos aos gráficos
```

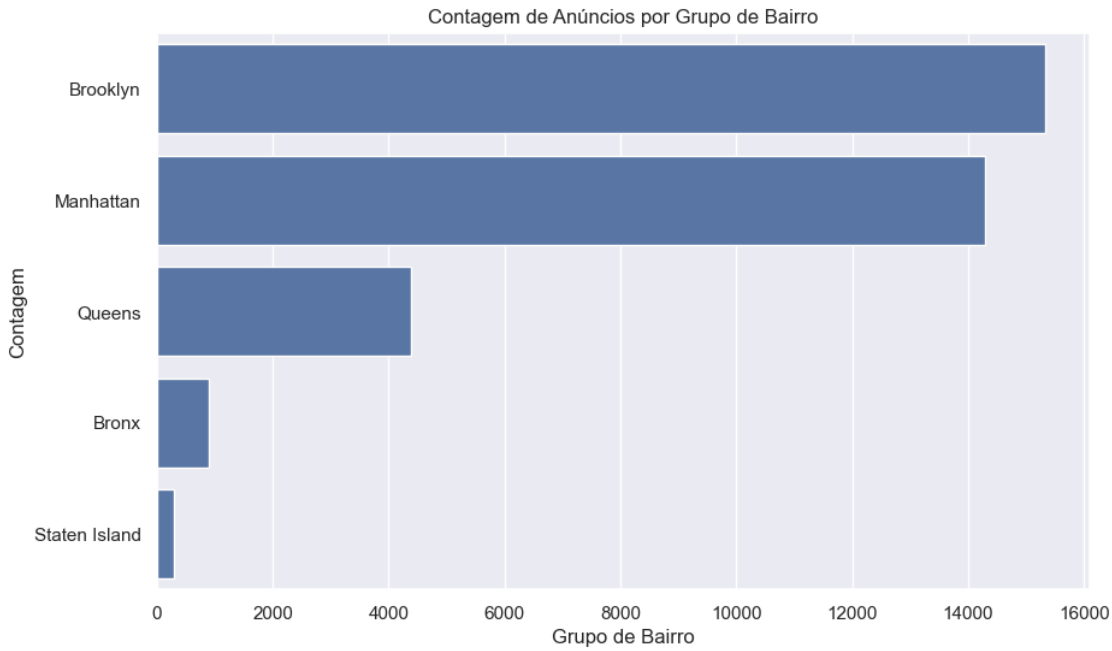

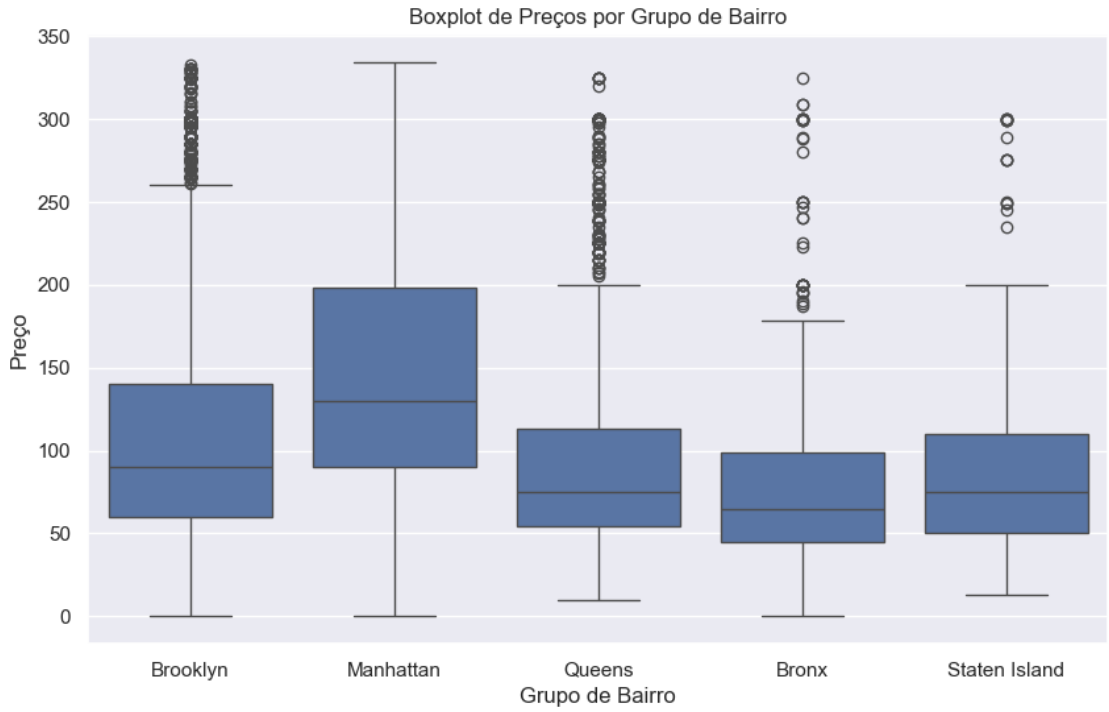

1.7.4 6.4) Top 10 Bairros com Mais Anúncios

Identificar os bairros com maior concentração de anúncios pode indicar áreas de alta demanda ou popularidade.

[15]:
```
# Calcule os 10 bairros com mais anúncios
top10_bairros_mais_anuncios = df["neighbourhood"].value_counts().head(10)

# Crie um gráfico de barras para visualizar esses bairros usando `sns.barplot`
plt.figure()
sns.barplot(top10_bairros_mais_anuncios)
plt.title("Top 10 Bairros com Mais Anúncios")
plt.xlabel("Bairro")
plt.ylabel("Número de Anúncios")
plt.xticks(rotation=45)
plt.show()

# Adicione títulos e rótulos aos gráficos, e rotacione os rótulos do eixo X se␣
↪necessário
```

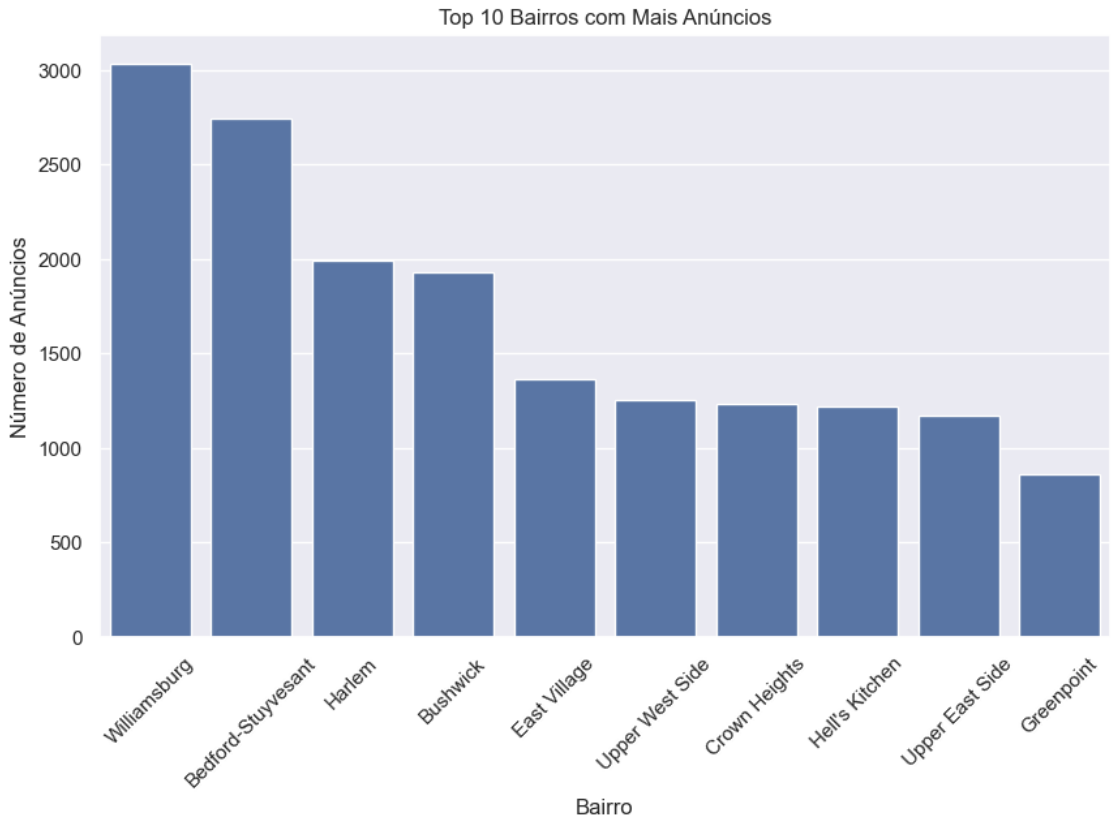

1.7.5 6.5) Análise Geoespacial dos Anúncios

Visualizar os anúncios em um mapa nos permite identificar clusters geográficos e entender a distribuição espacial dos imóveis.

[17]:
```
# Crie um mapa base de Nova York usando `folium.Map`
mapa_nyc = folium.Map(location=[40.7128, -74.0060], zoom_start=12)

# Adicione um `MarkerCluster` ao mapa
from folium.plugins import MarkerCluster
marker_cluster = MarkerCluster().add_to(mapa_nyc)

# Amostre uma parte do DataFrame (e.g., 5000 pontos) para melhor performance na␣
↪visualização
amostra_df = df.sample(n=5000, random_state=42)

# Adicione marcadores ao mapa para cada ponto amostrado, incluindo informações␣
↪no popup
for idx, row in amostra_df.iterrows():
    folium.Marker(
        location=[row["latitude"], row["longitude"]],
```

```
        popup=f"""
        <b>Nome:</b> {row['name']}<br>
        <b>Preço:</b> ${row['price']}<br>
        <b>Bairro:</b> {row['neighbourhood']}<br>
        <b>Tipo:</b> {row['room_type']}
        """
    ).add_to(marker_cluster)

# Salve o mapa em um arquivo HTML (e.g., "airbnb_nyc_map.html")
mapa_nyc.save("airbnb_nyc_map.html")

# (Opcional) Exiba o mapa diretamente no notebook se o ambiente suportar
mapa_nyc
```

[17]: <folium.folium.Map at 0x184b949f110>

1.8 7) Engenharia de Features

A engenharia de features envolve a criação de novas variáveis a partir das existentes para melhorar a capacidade preditiva dos modelos ou para obter novos insights. Aqui, criaremos algumas features simples.

1.8.1 7.1) `host_experience_days`

Calcularemos a experiência do anfitrião em dias, baseando-nos na data da última avaliação (`last_review`) e uma data de referência (ou a data da primeira avaliação, se disponível). Isso pode indicar a longevidade e experiência do anfitrião na plataforma.

[18]:
```
# Calcule a data mais recente de `last_review`
data_recente = df["last_review"].max()

# Crie a nova feature `host_experience_days` calculando a diferença em dias␣
↪entre a data mais recente e `last_review`
df["host_experience_days"] = (data_recente - df["last_review"]).dt.days

# Exiba as estatísticas descritivas da nova feature
df["host_experience_days"].describe()
```

[18]:
```
count    35202.000000
mean       912.940032
std       1301.936154
min          0.000000
25%         22.000000
50%        190.000000
75%       1150.000000
max       3475.000000
Name: host_experience_days, dtype: float64
```

1.8.2 7.2) price_per_night_per_review

Esta feature pode indicar o custo-benefício percebido, relacionando o preço por noite com o número de avaliações. Um valor baixo pode indicar um bom negócio, enquanto um valor alto pode sugerir um preço elevado para poucos reviews.

[19]:
```
# Crie a nova feature `price_per_night_per_review`, dividindo `price` por␣
↪`number_of_reviews`
# # Lembre-se de tratar a divisão por zero (e.g., se `number_of_reviews` for 0,␣
↪use o próprio `price`)
df["price_per_night_per_review"] = np.where(
    df["number_of_reviews"] == 0,
    df["price"],
    df["price"] / df["number_of_reviews"]
)

# Exiba as estatísticas descritivas da nova feature
df["price_per_night_per_review"].describe()
```

[19]:
```
count    35202.000000
mean        49.967902
std         63.791240
min          0.000000
25%          5.801613
50%         21.966667
75%         70.000000
max        333.000000
Name: price_per_night_per_review, dtype: float64
```

1.9 8) Análise de Correlação

A correlação mede a força e a direção da relação linear entre duas variáveis numéricas. Um mapa de calor (heatmap) da matriz de correlação é uma excelente ferramenta para visualizar essas relações.

[20]:
```
# Selecione apenas as colunas numéricas do DataFrame
colunas_numericas = df.select_dtypes(include=["int64", "float64"])

# Calcule a matriz de correlação
matriz_correlacao = colunas_numericas.corr()

# Crie um heatmap da matriz de correlação usando `sns.heatmap`
# Adicione anotações e um mapa de cores adequado
# Adicione um título ao gráfico
plt.figure()
sns.heatmap(matriz_correlacao, annot=True, cmap="coolwarm", fmt=".2f")
plt.title("Matriz de Correlação")
plt.show()
```

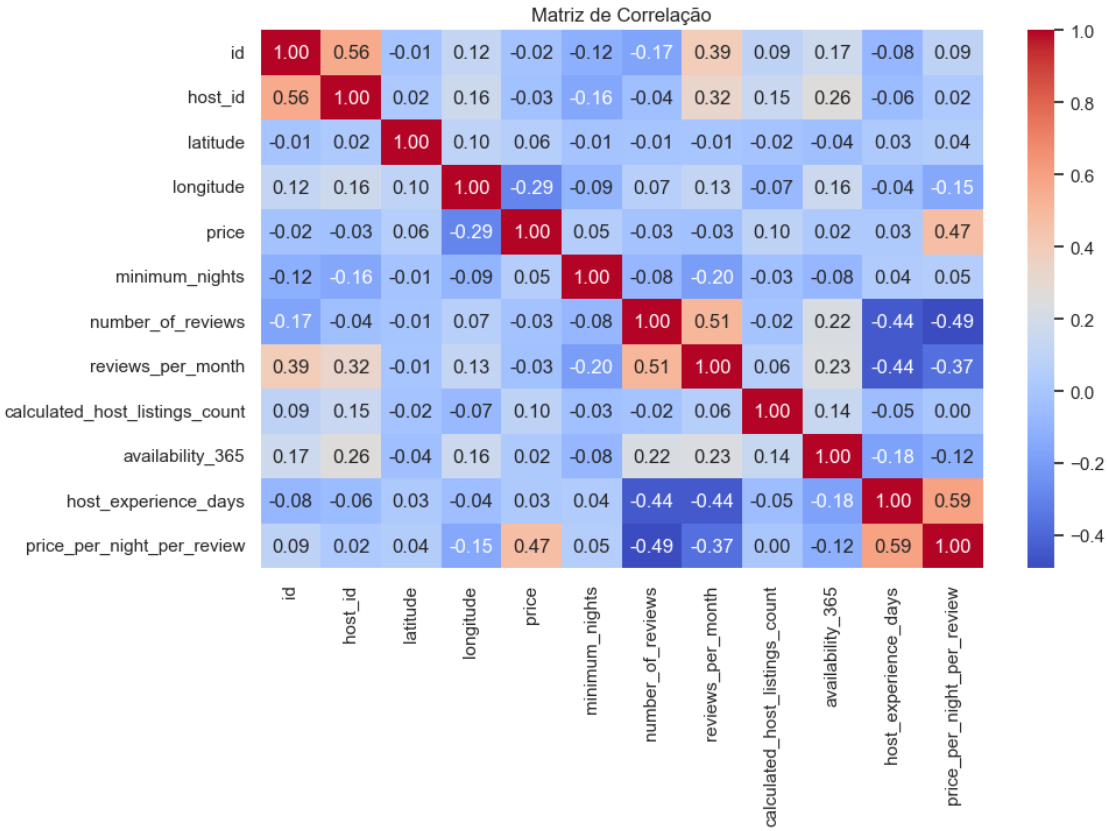
Matriz de Correlação
id 1.00 0.56 -0.01 0.12 -0.02 -0.12 -0.17 0.39 0.09 0.17 -0.08 0.09
host_id 0.56 1.00 0.02 0.16 -0.03 -0.16 -0.04 0.32 0.15 0.26 -0.06 0.02
latitude -0.01 0.02 1.00 0.10 0.06 -0.01 -0.01 -0.01 -0.02 -0.04 0.03 0.04
longitude 0.12 0.16 0.10 1.00 -0.29 -0.09 0.07 0.13 -0.07 0.16 -0.04 -0.15
price -0.02 -0.03 0.06 -0.29 1.00 0.05 -0.03 -0.03 0.10 0.02 0.03 0.47
minimum_nights -0.12 -0.16 -0.01 -0.09 0.05 1.00 -0.08 -0.20 -0.03 -0.08 0.04 0.05
number_of_reviews -0.17 -0.04 -0.01 0.07 -0.03 -0.08 1.00 0.51 -0.02 0.22 -0.44 -0.49
reviews_per_month 0.39 0.32 -0.01 0.13 -0.03 -0.20 0.51 1.00 0.06 0.23 -0.44 -0.37
calculated_host_listings_count 0.09 0.15 -0.02 -0.07 0.10 -0.03 -0.02 0.06 1.00 0.14 -0.05 0.00
availability_365 0.17 0.26 -0.04 0.16 0.02 -0.08 0.22 0.23 0.14 1.00 -0.18 -0.12
host_experience_days -0.08 -0.06 0.03 -0.04 0.03 0.04 -0.44 -0.44 -0.05 -0.18 1.00 0.59
price_per_night_per_review 0.09 0.02 0.04 -0.15 0.47 0.05 -0.49 -0.37 0.00 -0.12 0.59 1.00
id
host_id
latitude
longitude
price
minimum_nights
number_of_reviews
reviews_per_month
calculated_host_listings_count
availability_365
host_experience_days
price_per_night_per_review
1.0
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4