

✓ Aquisição e Integração de Dados do IBGE

Pegar estimativas populacionais (2015-2022) e realizar o merge com o DataFrame do SINESP.

```
# Importando bibliotecas e clonando repos
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import ttest_ind
from IPython.display import display
!git clone https://github.com/claytontey/Aulas_Git-DS.git
df = df_integrado.copy()
```

fatal: destination path 'Aulas_Git-DS' already exists and is not an empty directory.

```
# Carregar dados brutos do IBGE
path_pop = './Aulas_Git-DS/TP-1/Giovani_Pablo/dados/popUF(2015-2021).xlsx'
pop_raw = pd.read_excel(path_pop)

# Limpeza: Remover metadados e ajustar colunas
# Os anos estão na linha index 2, os dados começam na linha 3
pop_clean = pop_raw.iloc[3:30].copy()
pop_clean.columns = ['UF', '2015', '2016', '2017', '2018', '2019', '2020', '2021']
pop_clean = pop_clean[['UF', '2015', '2016', '2017', '2018', '2019', '2020', '2021']]

# Transformar para formato Long (Ano como coluna)
pop_long = pop_clean.melt(id_vars=['UF'], var_name='Ano', value_name='Populacao')

# Padronização essencial para o Merge
pop_long['Ano'] = pop_long['Ano'].astype(int)
pop_long['Populacao'] = pd.to_numeric(pop_long['Populacao'], errors='coerce')
pop_long['UF'] = pop_long['UF'].str.strip().str.upper()

print("Dados Populacionais prontos para integração:")
display(pop_long.head())
print(pop_long.info())
```

Dados Populacionais prontos para integração:

	UF	Ano	Populacao
0	RONDÔNIA	2015	1768204
1	ACRE	2015	803513
2	AMAZONAS	2015	3938336
3	RORAIMA	2015	505665
4	PARÁ	2015	8175113

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 189 entries, 0 to 188
Data columns (total 3 columns):
#   Column      Non-Null Count  Dtype
---  -
0    UF          189 non-null    object
1    Ano         189 non-null    int64
2    Populacao   189 non-null    int64
dtypes: int64(2), object(1)
memory usage: 4.6+ KB
None
```

```
# Carregar dados do SINESP
ocorrencias_df = pd.read_csv('./Aulas_Git-DS/TP-1/Giovani_Pablo/ocorrencias_limpo.csv')

# Padronizar SINESP para o Merge
ocorrencias_df['Ano'] = ocorrencias_df['Ano'].astype(int)
ocorrencias_df['UF'] = ocorrencias_df['UF'].str.strip().str.upper()

# Realizar o Merge Final
df_integrado = pd.merge(
    ocorrencias_df,
    pop_long,
    on=['UF', 'Ano'],
    how='inner'
)

# Cálculo da Taxa por 100k habitantes
df_integrado['Taxa_por_100k'] = (df_integrado['Ocorrências'] / df_integrado['Populacao']) * 100000
```



```
# 1. Agregado por Ano e Estado
df_ano_uf = df_integrado.groupby(['Ano', 'UF', 'Regiao']).agg({
    'Ocorrências': 'sum',
    'Populacao': 'mean', # Média pois a população é a mesma para todos os crimes no mesmo ano/UF
    'Taxa_por_100k': 'sum'
}).reset_index()

# 2. Agregado por Região
df_regiao = df_integrado.groupby(['Ano', 'Regiao']).agg({
    'Ocorrências': 'sum',
    'Populacao': 'sum' # Aqui somamos a população de todos os estados da região
}).reset_index()
df_regiao['Taxa_por_100k'] = (df_regiao['Ocorrências'] / df_regiao['Populacao']) * 100000

# 3. Agregado por Tipo de Crime
df_crime = df_integrado.groupby(['Tipo Crime', 'Ano']).agg({
    'Ocorrências': 'sum'
}).reset_index()

print("DataFrames agregados criados com sucesso!")
display(df_ano_uf.head())
display(df_regiao.head())
display(df_crime.head())
```

DataFrames agregados criados com sucesso!

	Ano	UF	Regiao	Ocorrências	Populacao	Taxa_por_100k
0	2015	ACRE	Norte	260	803513.0	32.357908
1	2015	ALAGOAS	Nordeste	6939	3340932.0	207.696535
2	2015	AMAPÁ	Norte	2125	766679.0	277.169454
3	2015	AMAZONAS	Norte	7240	3938336.0	183.833985
4	2015	BAHIA	Nordeste	31531	15203334.0	207.395299

	Ano	Regiao	Ocorrências	Populacao	Taxa_por_100k
0	2015	Centro-Oeste	60540	1667761056	3.630016
1	2015	Nordeste	118015	6108423948	1.932004
2	2015	Norte	37892	1877077861	2.018670
3	2015	Sudeste	345019	8727758352	3.953123
4	2015	Sul	104520	3022903224	3.457603

	Tipo Crime	Ano	Ocorrências
0	ESTUPRO	2015	43591
1	ESTUPRO	2016	46779
2	ESTUPRO	2017	50513
3	ESTUPRO	2018	53233
4	ESTUPRO	2019	53936

✦ Taxa de Letalidade vs Patrimônio

```
# Ordem dos meses
ordem_meses = {
    'JANEIRO': 1,
    'FEVEREIRO': 2,
    'MARÇO': 3,
    'ABRIL': 4,
    'MAIO': 5,
    'JUNHO': 6,
    'JULHO': 7,
    'AGOSTO': 8,
    'SETEMBRO': 9,
    'OUTUBRO': 10,
    'NOVEMBRO': 11,
    'DEZEMBRO': 12
}

df['Mes_num'] = df['Mês'].map(ordem_meses)

#1. Homicídio doloso por UF e Ano
homicidio = (
```

```

df[df['Tipo Crime'] == 'HOMICÍDIO DOLOSO']
.groupby(['UF', 'Ano'], as_index=False)
.agg(
    homicidios=('Ocorrências', 'sum'),
    Populacao=('Populacao', 'mean')
)

# 2. Todos os roubos por UF e Ano
roubos = (
    df[df['Tipo Crime'].str.contains('ROUBO', case=False, na=False)]
    .groupby(['UF', 'Ano'], as_index=False)
    .agg(
        roubos=('Ocorrências', 'sum')
    )
)

# 3. Juntar as duas bases
comp = homicidio.merge(roubos, on=['UF', 'Ano'], how='inner')

# 4. Recalcular as taxas por 100 mil habitantes
comp['Taxa_Homicidio_100k'] = (comp['homicidios'] / comp['Populacao']) * 100000
comp['Taxa_Roubo_100k'] = (comp['roubos'] / comp['Populacao']) * 100000


# 5. Correlação
correlacao = comp['Taxa_Homicidio_100k'].corr(comp['Taxa_Roubo_100k'])

print(f'Correlação entre taxa de homicídio e taxa de roubo: {correlacao:.4f}')

# 6. Scatter plot
plt.figure(figsize=(10, 6))
sns.regplot(
    data=comp,
    x='Taxa_Roubo_100k',
    y='Taxa_Homicidio_100k',
    scatter_kws={'alpha': 0.7}
)
plt.title(f'Taxa de Homicídio Doloso vs Taxa de Roubos\nCorrelação = {correlacao:.3f}')
plt.xlabel('Taxa de Roubos por 100 mil hab.')
plt.ylabel('Taxa de Homicídios Dolosos por 100 mil hab.')
plt.grid(True, alpha=0.3)
plt.show()

```

Correlação entre taxa de homicídio e taxa de roubo: 0.2055



✓ Efeito Sazonal (Dezembro)

dezembro apresenta comportamento diferente da média dos outros meses?

```
crimes_sazonais = [
    'ROUBO DE CARGA',
    'ROUBO A INSTITUIÇÃO FINANCEIRA'
]

df_sazonal = df[df['Tipo Crime'].isin(crimes_sazonais)].copy()

# Agregar por crime, ano e mês, recalculando a taxa
sazonal = (
    df_sazonal
    .groupby(['Tipo Crime', 'Ano', 'Mês', 'Mes_num'], as_index=False)
    .agg(
        Ocorrencias=('Ocorrências', 'sum'),
        Populacao=('Populacao', 'sum')
    )
)

sazonal['Taxa_por_100k'] = (sazonal['Ocorrencias'] / sazonal['Populacao']) * 100000

# Média mensal ao longo dos anos
media_mensal = (
    sazonal
    .groupby(['Tipo Crime', 'Mês', 'Mes_num'], as_index=False)
    .agg(Media_Taxa_100k=('Taxa_por_100k', 'mean'))
    .sort_values(['Tipo Crime', 'Mes_num'])
)

display(media_mensal)
```

	Tipo Crime	Mês	Mes_num	Media_Taxa_100k
4	ROUBO A INSTITUIÇÃO FINANCEIRA	JANEIRO	1	0.033095
3	ROUBO A INSTITUIÇÃO FINANCEIRA	FEVEREIRO	2	0.033777
8	ROUBO A INSTITUIÇÃO FINANCEIRA	MARÇO	3	0.036407
0	ROUBO A INSTITUIÇÃO FINANCEIRA	ABRIL	4	0.029345
7	ROUBO A INSTITUIÇÃO FINANCEIRA	MAIO	5	0.031135
6	ROUBO A INSTITUIÇÃO FINANCEIRA	JUNHO	6	0.028707
5	ROUBO A INSTITUIÇÃO FINANCEIRA	JULHO	7	0.027829
1	ROUBO A INSTITUIÇÃO FINANCEIRA	AGOSTO	8	0.026387
11	ROUBO A INSTITUIÇÃO FINANCEIRA	SETEMBRO	9	0.026788
10	ROUBO A INSTITUIÇÃO FINANCEIRA	OUTUBRO	10	0.029359
9	ROUBO A INSTITUIÇÃO FINANCEIRA	NOVEMBRO	11	0.028760
2	ROUBO A INSTITUIÇÃO FINANCEIRA	DEZEMBRO	12	0.029480
16	ROUBO DE CARGA	JANEIRO	1	0.803715
15	ROUBO DE CARGA	FEVEREIRO	2	0.704210
20	ROUBO DE CARGA	MARÇO	3	0.807792
12	ROUBO DE CARGA	ABRIL	4	0.767105
19	ROUBO DE CARGA	MAIO	5	0.786842
18	ROUBO DE CARGA	JUNHO	6	0.759310
17	ROUBO DE CARGA	JULHO	7	0.760975
13	ROUBO DE CARGA	AGOSTO	8	0.748987
23	ROUBO DE CARGA	SETEMBRO	9	0.694967
22	ROUBO DE CARGA	OUTUBRO	10	0.775259
21	ROUBO DE CARGA	NOVEMBRO	11	0.810899
14	ROUBO DE CARGA	DEZEMBRO	12	0.910420

Próximas etapas: [Gerar código com media_mensal](#) [New interactive sheet](#)

```
#Grafico da Media Mensal
plt.figure(figsize=(12, 6))
sns.lineplot(
    data=media_mensal,
    x='Mes_num',
    y='Media_Taxa_100k',
    hue='Tipo Crime',


```

```

marker='o'
)

plt.xticks(range(1, 13), [
    'Jan', 'Fev', 'Mar', 'Abr', 'Mai', 'Jun',
    'Jul', 'Ago', 'Set', 'Out', 'Nov', 'Dez'
])
plt.title('Média Mensal da Taxa por 100 mil hab.')
plt.xlabel('Mês')
plt.ylabel('Taxa média por 100 mil hab.')
plt.grid(True, alpha=0.3)
plt.show()

```



```

#Teste Final se dezembro efetivamente foge do padrão
#Media_Dezembro > Media_Outros_Meses → dezembro tem taxa maior.
#p_valor < 0.05 → há evidência de que dezembro difere dos outros meses.
#|Zscore_Dezembro| > 2 → dezembro foge bem do padrão.

resultados_dezembro = []

for crime in crimes_sazonais:
    base = sazonal[sazonal['Tipo Crime'] == crime]

    dezembro = base[base['Mês'] == 'DEZEMBRO']['Taxa_por_100k']
    outros = base[base['Mês'] != 'DEZEMBRO']['Taxa_por_100k']

    # teste t de Welch
    t_stat, p_valor = ttest_ind(dezembro, outros, equal_var=False, nan_policy='omit')

    media_dez = dezembro.mean()
    media_outros = outros.mean()
    desvio_outros = outros.std()

    z_score_dez = np.nan
    if pd.notnull(desvio_outros) and desvio_outros != 0:
        z_score_dez = (media_dez - media_outros) / desvio_outros

    resultados_dezembro.append({
        'Tipo Crime': crime,
        'Media_Dezembro': media_dez,
        'Media_Outros_Meses': media_outros,
        'Diferenca': media_dez - media_outros,
        'Zscore_Dezembro': z_score_dez,
        'p_valor': p_valor
    })

resultado_dezembro_df = pd.DataFrame(resultados_dezembro)
display(resultado_dezembro_df)

```

	Tipo Crime	Media_Dezembro	Media_Outros_Meses	Diferenca	Zscore_Dezembro	p_valor	
0	ROUBO DE CARGA	0.91042	0.765460	0.144960	0.717885	0.228240	
1	ROUBO A INSTITUIÇÃO FINANCEIRA	0.02948	0.030145	-0.000664	-0.041212	0.918532	

Próximas etapas:

[Gerar código com resultado_dezembro_df](#)[New interactive sheet](#)

▼ Anomalia Pandêmica

Quedas em 2020 e suas recuperações até 2021("Não possuímos os dados de 2022")

```
#taxa anual por tipo de crime
anual = (
    df.groupby(['Tipo Crime', 'Ano'], as_index=False)
    .agg(
        Ocorrencias=('Ocorrências', 'sum'),
        Populacao=('Populacao', 'sum')
    )
)

anual['Taxa_por_100k'] = (anual['Ocorrencias'] / anual['Populacao']) * 100000

#quedas em 2020
pivot_anual = anual.pivot(index='Tipo Crime', columns='Ano', values='Taxa_por_100k')

# Garantir que 2019 e 2020 existam
if 2019 in pivot_anual.columns and 2020 in pivot_anual.columns:
    pivot_anual['Queda_2020_pct'] = ((pivot_anual[2020] - pivot_anual[2019]) / pivot_anual[2019]) * 100
    maiores_quedas = pivot_anual.sort_values('Queda_2020_pct').reset_index()

    print("Crimes com maior queda percentual em 2020:")
    display(maiores_quedas[['Tipo Crime', 'Queda_2020_pct']].head(10))
else:
    print("Os anos de 2019 e 2020 não estão disponíveis na base.")
```

Crimes com maior queda percentual em 2020:


Ano	Tipo Crime	Queda_2020_pct	
0	ROUBO DE VEÍCULO	-24.862720	
1	ROUBO DE CARGA	-24.050775	
2	ROUBO A INSTITUIÇÃO FINANCEIRA	-24.008055	
3	FURTO DE VEÍCULO	-21.405714	
4	LESÃO CORPORAL SEGUIDA DE MORTE	-13.968282	
5	ESTUPRO	-11.685268	
6	ROUBO SEGUIDO DE MORTE (LATROCÍNIO)	-11.326099	
7	TENTATIVA DE HOMICÍDIO	-8.664033	
8	HOMICÍDIO DOLOSO	6.052068	

```
#Gráfico temporal por tipo de crime
#Buscamos mostrar os crimes com maior queda em 2020
top_crimes = maiores_quedas['Tipo Crime'].head(5).tolist()

plot_df = anual[anual['Tipo Crime'].isin(top_crimes)]


plt.figure(figsize=(12, 7))
sns.lineplot(
    data=plot_df,
    x='Ano',
    y='Taxa_por_100k',
    hue='Tipo Crime',
    marker='o'
)

plt.title('Anomalia Pandêmica: Evolução da Taxa por 100 mil hab. por Tipo de Crime')
plt.xlabel('Ano')
plt.ylabel('Taxa por 100 mil hab.')
plt.grid(True, alpha=0.3)
plt.show()
```



Impacto da Pandemia (Série Temporal Anual)

```
plt.figure(figsize=(10, 6))
sns.lineplot(data=df_regiao, x='Ano', y='Taxa_por_100k', hue='Regiao', marker='s')
plt.title('Evolução das Taxas de Crime por Região (Pré e Pós Pandemia)')
plt.ylabel('Ocorrências por 100k habitantes')
plt.grid(True, alpha=0.3)
plt.show()
```



#Análise dessa "Recuperação"

```
pivot = anual.pivot(index='Tipo Crime', columns='Ano', values='Taxa_por_100k')

# garantir anos
pivot = pivot[[2019, 2020, 2021]].dropna()
```



```
# variações
pivot['Queda_2020_%'] = ((pivot[2020] - pivot[2019]) / pivot[2019]) * 100
pivot['Recuperacao_2021_%'] = ((pivot[2021] - pivot[2020]) / pivot[2020]) * 100

# classificação
def classificar(row):
    if row[2021] >= row[2019]:
        return 'Recuperação total'
    elif row[2021] > row[2020]:
        return 'Recuperação parcial'
    else:
        return 'Sem recuperação'

pivot['Status'] = pivot.apply(classificar, axis=1)

resultado = pivot.reset_index().sort_values('Queda_2020_%')
display(resultado)
```

Ano	Tipo Crime	2019	2020	2021	Queda_2020_%	Recuperacao_2021_%	Status	
6	ROUBO DE VEÍCULO	7.337074	5.512878	5.343909	-24.862720	-3.064995	Sem recuperação	
5	ROUBO DE CARGA	0.702673	0.533675	0.530144	-24.050775	-0.661565	Sem recuperação	
4	ROUBO A INSTITUIÇÃO FINANCEIRA	0.017017	0.012932	0.015123	-24.008055	16.941970	Recuperação parcial	
1	FURTO DE VEÍCULO	8.713384	6.848222	7.277684	-21.405714	6.271143	Recuperação parcial	
3	LESÃO CORPORAL SEGUIDA DE MORTE	0.033770	0.029053	0.020001	-13.968282	-31.154650	Sem recuperação	
0	ESTUPRO	2.144788	1.894164	2.064091	-11.685268	8.971103	Recuperação parcial	
7	ROUBO SEGUIDO DE MORTE (LATROCÍNIO)	0.059086	0.052393	0.054262	-11.326099	3.565915	Recuperação parcial	


Próximas etapas: [Gerar código com resultado](#) [New interactive sheet](#)

```
#Novo Gráfico e coorelação dos dados

plt.figure(figsize=(12, 7))

sns.lineplot(
    data=anual,
    x='Ano',
    y='Taxa_por_100k',
    hue='Tipo Crime',
    estimator=None
)

plt.axvline(2020, color='red', linestyle='--', label='Início pandemia')
plt.title('Impacto da pandemia e recuperação em 2021')
plt.ylabel('Taxa por 100 mil hab.')
plt.grid(True, alpha=0.3)
plt.legend()
plt.show()
```



Ranking de Evolução

```
#Separando por UF e Ano

df_uf_ano = (
    df.groupby(['UF', 'Ano'], as_index=False)
    .agg(
        Ocorrencias=('Ocorrências', 'sum'),
        Populacao=('Populacao', 'sum')
    )
)

df_uf_ano['Taxa_por_100k'] = (
    df_uf_ano['Ocorrencias'] / df_uf_ano['Populacao']
) * 100000

df_uf_ano = df_uf_ano.sort_values(['UF', 'Ano'])

#Variação Ano a Ano
df_uf_ano['Variacao'] = (
    df_uf_ano
    .groupby('UF')['Taxa_por_100k']
    .pct_change()
)

#Possíveis quedas consecutivas para um unico tipo;
df_uf_ano['queda'] = df_uf_ano.groupby('UF')['Variacao'].transform(lambda x: x < 0)

df_uf_ano['3_quedas'] = (
    df_uf_ano.groupby('UF')['queda']
    .transform(lambda x: x.rolling(3).sum() == 3)
)

#Agora ja tendo as possiveis quedas iremos para uma analise mais focada em identificar os Estados que possuem ao minimo uma queda consecutiva de 3 anos

estados_queda = (
    df_uf_ano[df_uf_ano['3_quedas']]
    .groupby('UF')
    .agg(
        ocorrencias_sequencia=('3_quedas', 'sum')
    )
    .reset_index()
)
```

#Por fim iniciaremos um display para uma visualização visual do que foi feito sobre as possíveis sequências de resultados

```
queda_info = df_uf_ano[df_uf_ano['3_quedas']].copy()

queda_info['queda_total'] = (
    queda_info.groupby('UF')['Taxa_por_100k'].transform('first') -
    queda_info.groupby('UF')['Taxa_por_100k'].transform('last')
)

ranking_final = (
    queda_info.groupby('UF')
    .agg(
        qtd_sequencias=('3_quedas', 'sum'),
        queda_total=('queda_total', 'mean')
    )
    .reset_index()
    .sort_values(['qtd_sequencias', 'queda_total'], ascending=[False, False])
)

display(ranking_final)
```

	UF	qtd_sequencias	queda_total	
15	RIO GRANDE DO SUL	4	1.597058	
1	AMAPÁ	3	1.433820	
20	SÃO PAULO	3	1.311703	
4	DISTRITO FEDERAL	3	1.033242	
5	GOIÁS	3	0.984755	
10	PARANÁ	3	0.572462	
8	MATO GROSSO DO SUL	3	0.566634	
7	MATO GROSSO	3	0.519573	
9	MINAS GERAIS	3	0.457344	
18	SANTA CATARINA	3	0.291005	
0	ALAGOAS	3	0.278968	
19	SERGIPE	3	0.259664	
6	MARANHÃO	2	0.187836	
3	BAHIA	2	0.167974	
12	PERNAMBUCO	2	0.093902	
13	RIO DE JANEIRO	2	0.025103	
2	AMAZONAS	1	0.000000	
11	PARÁ	1	0.000000	
14	RIO GRANDE DO NORTE	1	0.000000	
16	RONDÔNIA	1	0.000000	
17	RORAIMA	1	0.000000	

Próximas etapas: [Gerar código com ranking_final](#) [New interactive sheet](#)

✓ Correlação entre crimes

```
#Lista dos crimes
crimes_lista = [
    'ROUBO DE VEÍCULO',
    'LATROCÍNIO',
    'HOMICÍDIO DOLOSO',
    'FURTO DE VEÍCULO'
]

#Agregando-os
df_corr = df[df['Tipo Crime'].isin(crimes_lista)].copy()

df_corr = (
    df_corr.groupby(['UF', 'Ano', 'Tipo Crime'], as_index=False)
    .agg(
        Ocorrências=('Ocorrências', 'sum'),

```

```

Populacao=('Populacao', 'sum')
)
)


df_corr['Taxa_por_100k'] = (
    df_corr['Ocorrências'] / df_corr['Populacao']
) * 100000

pivot = df_corr.pivot(
    index=['UF', 'Ano'],
    columns='Tipo Crime',
    values='Taxa_por_100k'
).dropna()

#Correlação e Heatmap
correlacao = pivot.corr()

plt.figure(figsize=(8, 6))
sns.heatmap(correlacao, annot=True, cmap="coolwarm", center=0)
plt.title('Heatmap de Correlação entre Tipos de Crime')
plt.show()

```




```

# Correlação entre tipos de crime

# Pivotar para ter tipos de crime como colunas
corr_matrix = df_integrado.pivot_table(index=['UF', 'Ano', 'Mês'], columns='Tipo Crime', values='Ocorrências', aggfunc='sum')

plt.figure(figsize=(12, 10))
sns.heatmap(corr_matrix, annot=True, cmap='RdBu_r', fmt='.2f', center=0)
plt.title('Matriz de Correlação entre Tipos de Crimes')
plt.show()

```



01 • Letalidade vs. Patrimônio

A correlação é fraca (0,21), explicando apenas ~4% da variância. Estados com muitos roubos não são necessariamente os mais letais — são fenômenos com determinantes distintos.

02 • Efeito Sazonal

Dezembro não confirma o efeito "festas" estatisticamente. O roubo de carga sobe +18,9% em dezembro visualmente, mas com p-valor = 0,228 (não significativo). Roubo a instituições financeiras até cai ligeiramente.

03 • Anomalia Pandêmica

Roubo de Veículo teve a queda mais abrupta em 2020 (-24,9%), seguido de roubo de carga e roubo a bancos. Em 2021 nenhum deles voltou ao nível pré-pandemia. O homicídio doloso foi o único que subiu (+6%), contra a tendência geral.

04 • Ranking de Evolução

Rio Grande do Sul é o único estado com 4 sequências consecutivas de queda — desempenho isolado. São Paulo, DF, Goiás e outros 5 estados alcançaram 3 sequências. Estados do Norte não passaram de 1.

05 · Correlação entre Tipos

A correlação entre roubo de veículos e latrocínio é fraca. O achado mais relevante é a correlação negativa de $-0,54$ entre furto de veículo e homicídio doloso, sugerindo perfis regionais de criminalidade opostos.

Interpretação dos Resultados e Conclusões

1. Dinâmica dos Crimes e Correlação

Observamos uma **correlação de Pearson de -0.20** entre crimes contra o patrimônio e homicídios. Isso sugere que, no Brasil, estados com altas taxas de roubos/furtos não necessariamente apresentam as maiores taxas de homicídios. Essa desconexão pode indicar dinâmicas criminais distintas: enquanto o crime patrimonial está muito ligado a centros urbanos e atividade econômica, os crimes letais podem estar mais relacionados a conflitos territoriais e crime organizado.

2. O Fenômeno da Sazonalidade (Dezembro)