Limpeza e preparação dos dados

1. carregar o dataset e mostrar as informações

In [1]:
```
import pandas as pd
import numpy as np
df = pd.read_csv('Preços semestrais - AUTOMOTIVOS_2025.02.csv', sep=';', encodin
print("--- Informações do Dataset ---")
display(df.info())
print("\n--- Valores Nulos por Coluna ---")
display(df.isnull().sum())
```

```
--- Informações do Dataset ---
<class 'pandas.DataFrame'>
RangeIndex: 384208 entries, 0 to 384207
Data columns (total 16 columns):
 #   Column             Non-Null Count   Dtype
---  ------             --------------   -----
 0   Regiao - Sigla     384208 non-null  str
 1   Estado - Sigla     384208 non-null  str
 2   Municipio          384208 non-null  str
 3   Revenda            384208 non-null  str
 4   CNPJ da Revenda    384208 non-null  int64
 5   Nome da Rua        384208 non-null  str
 6   Numero Rua         384184 non-null  str
 7   Complemento        86707 non-null   str
 8   Bairro             383546 non-null  str
 9   Cep                384208 non-null  str
 10  Produto            384208 non-null  str
 11  Data da Coleta     384208 non-null  str
 12  Valor de Venda     384208 non-null  str
 13  Valor de Compra    0 non-null       float64
 14  Unidade de Medida  384208 non-null  str
 15  Bandeira           384208 non-null  str
dtypes: float64(1), int64(1), str(14)
memory usage: 46.9 MB
None
--- Valores Nulos por Coluna ---
Regiao - Sigla            0
Estado - Sigla            0
Municipio                 0
Revenda                   0
CNPJ da Revenda           0
Nome da Rua               0
Numero Rua               24
Complemento          297501
Bairro                  662
Cep                       0
Produto                   0
Data da Coleta            0
Valor de Venda            0
Valor de Compra      384208
Unidade de Medida         0
Bandeira                  0
dtype: int64
```

2.Tratamento dos Dados e preparação para análise

In [2]:
```
#copia para nao alterar os dados originais
df_clean = df.copy()
#remover colunas desnecessarias para as perguntas
colunas_remover = ['Valor de Compra', 'Complemento', 'Nome da Rua', 'Numero Rua'
df_clean = df_clean.drop(columns=colunas_remover)
#ajustar o valor de venda e transformar em float
df_clean['Valor de Venda'] = df_clean['Valor de Venda'].astype(str).str.replace(
#transformar data no formato datetime
df_clean['Data da Coleta'] = pd.to_datetime(df_clean['Data da Coleta'], format='
#criar a coluna mes
df_clean['Mes'] = df_clean['Data da Coleta'].dt.month
#lidar com dados faltantes
df_clean = df_clean.dropna(subset=['Valor de Venda', 'Produto'])
#verificar o resultado pos limpeza
print("--- Dimensões do dataset limpo ---")
print(df_clean.shape)
display(df_clean.head())
```

```
--- Dimensões do dataset limpo ---
(384208, 11)
```

	Regiao - Sigla	Estado - Sigla	Municipio	Revenda	Bairro	Produto	Data da Coleta	Valor de Venda	Ur M
0	NE	AL	DELMIRO GOUVEIA	COMERCIO DE COMBUSTIVEIS NENZITA LTDA	PEDRA VELHA	DIESEL	2025-07-01	6.69	RS
1	N	AP	MACAPA	SEPE TIARAJU EMPREENDIMENTOS LTDA	ARAXÁ	DIESEL	2025-07-01	6.33	RS
2	NE	BA	IPIRA	AUTO POSTO AUGUSTU'S LTDA	SEDE	DIESEL	2025-07-01	6.90	RS
3	NE	BA	ITAMARAJU	CODEPEL - COMERCIO DE DERIVADOS DE PETROLEO LTDA	CENTRO	DIESEL	2025-07-01	5.99	RS
4	NE	BA	ITAMARAJU	BENTIVI DERIVADOS DE PETROLEO LTDA	SEDE	DIESEL	2025-07-01	5.92	RS

2.1Tratamento dos dados do dataset da frota de veiculos

In [ ]:
```
#segundo dataset
#carregar o segundo dataset
df_frota = pd.read_csv('frota_dezembro_2025.csv', sep=';', encoding='utf-8')
# display inicial para ve como as colunas estão configuradas
display(df_frota.head())
```

```
#print para ver o nome da exato das colunas
print(df_frota.columns.tolist())
```

	UF	MunicÃpio	Marca Modelo	Ano FabricaÃ§Ã£o VeÃculo CRV	Qtd. VeÃ-culos
0	ACRE	ACRELANDIA	AGRALE/13000	2009	1.0
1	ACRE	ACRELANDIA	AGRALE/1800	1989	1.0
2	ACRE	ACRELANDIA	AGRALE/1800	1990	1.0
3	ACRE	ACRELANDIA	AGRALE/1800DRD	1989	1.0
4	ACRE	ACRELANDIA	AGRALE/1800DRD	1990	2.0

```
['UF', 'MunicÃ\xadpio', 'Marca Modelo', 'Ano FabricaÃ§Ã£o VeÃ\xadculo CRV', 'Qtd.
VeÃ\xadculos']
```

In [5]:
```
#limpando a coluna municipio
df_clean['Municipio'] = df_clean['Municipio'].str.upper().str.strip()
df_clean['Municipio'] = df_clean['Municipio'].str.normalize('NFKD').str.encode('
#limpando a coluna com nome quebrado
df_frota['MunicÃ\xadpio'] = df_frota['MunicÃ\xadpio'].str.upper().str.strip()
df_frota['MunicÃ\xadpio'] = df_frota['MunicÃ\xadpio'].str.normalize('NFKD').str.
```

In [6]:
```
#Mudando o nome quebrado das colunas
df_frota = df_frota.rename(columns={
    'UF': 'Estado - Sigla',
    'MunicÃ\xadpio': 'Municipio',
    'Qtd. VeÃ\xadculos': 'Qtd_Veiculos'
})
# Limpeza no dataset de combustiveis
df_clean['Municipio'] = df_clean['Municipio'].astype(str).str.upper().str.strip(
df_clean['Municipio'] = df_clean['Municipio'].str.normalize('NFKD').str.encode('
df_clean['Estado - Sigla'] = df_clean['Estado - Sigla'].astype(str).str.upper().
# Limpeza no dataset da frota nacional
df_frota['Municipio'] = df_frota['Municipio'].astype(str).str.upper().str.strip(
df_frota['Municipio'] = df_frota['Municipio'].str.normalize('NFKD').str.encode('
df_frota['Estado - Sigla'] = df_frota['Estado - Sigla'].astype(str).str.upper().
#Como os datasets tratam o nome dos estados de forma diferente, vamos ter que mo
dicionario_estados = {
    'ACRE': 'AC', 'ALAGOAS': 'AL', 'AMAPA': 'AP', 'AMAZONAS': 'AM', 'BAHIA': 'BA
    'CEARA': 'CE', 'DISTRITO FEDERAL': 'DF', 'ESPIRITO SANTO': 'ES', 'GOIAS': 'G
    'MARANHAO': 'MA', 'MATO GROSSO': 'MT', 'MATO GROSSO DO SUL': 'MS', 'MINAS GE
    'PARA': 'PA', 'PARAIBA': 'PB', 'PARANA': 'PR', 'PERNAMBUCO': 'PE', 'PIAUI':
    'RIO DE JANEIRO': 'RJ', 'RIO GRANDE DO NORTE': 'RN', 'RIO GRANDE DO SUL': 'R
    'RONDONIA': 'RO', 'RORAIMA': 'RR', 'SANTA CATARINA': 'SC', 'SAO PAULO': 'SP'
    'SERGIPE': 'SE', 'TOCANTINS': 'TO'
}
#usando o dicionario_estados, concluimos a troca para padronizar a tabela
df_frota['Estado - Sigla'] = df_frota['Estado - Sigla'].replace(dicionario_estad
# Agrupar o dataset e merge
frota_municipal = df_frota.groupby(['Estado - Sigla', 'Municipio'])['Qtd_Veiculo
frota_municipal = frota_municipal.rename(columns={'Qtd_Veiculos': 'Frota_da_Cida
df_final_detalhado = pd.merge(df_clean, frota_municipal, on=['Estado - Sigla', '
display(df_final_detalhado.head())
```

	Regiao - Sigla	Estado - Sigla	Municipio	Revenda	Bairro	Produto	Data da Coleta	Valor de Venda	Ur M
0	NE	AL	DELMIRO GOUVEIA	COMERCIO DE COMBUSTIVEIS NENZITA LTDA	PEDRA VELHA	DIESEL	2025-07-01	6.69	R$
1	N	AP	MACAPA	SEPE TIARAJU EMPREENDIMENTOS LTDA	ARAXÁ	DIESEL	2025-07-01	6.33	R$
2	NE	BA	IPIRA	AUTO POSTO AUGUSTU'S LTDA	SEDE	DIESEL	2025-07-01	6.90	R$
3	NE	BA	ITAMARAJU	CODEPEL - COMERCIO DE DERIVADOS DE PETROLEO LTDA	CENTRO	DIESEL	2025-07-01	5.99	R$
4	NE	BA	ITAMARAJU	BENTIVI DERIVADOS DE PETROLEO LTDA	SEDE	DIESEL	2025-07-01	5.92	R$

In [7]:
```
#como utilizei dados da frota nacional de dezembro, vou colocar apenas o mes 12
#copia do dataset final, porem, apenas com o mes 12
df_dezembro = df_final_detalhado[df_final_detalhado['Mes'] == 12].copy()
#comparar o numero de linhas de cada um.
print("--- Quantidade de Linhas ---")
print("Dataset Original (Julho a Dezembro):", len(df_final_detalhado))
print("Dataset Filtrado (Apenas Dezembro):", len(df_dezembro))
#print final com os dados apenas do ultimo mes.
print("\n--- Amostra dos Dados de Dezembro ---")
display(df_dezembro.head())
```

```
--- Quantidade de Linhas ---
Dataset Original (Julho a Dezembro): 384208
Dataset Filtrado (Apenas Dezembro): 75580

--- Amostra dos Dados de Dezembro ---
```

	Regiao - Sigla	Estado - Sigla	Municipio	Revenda	Bairro	Produto	Data da Coleta	Valo d Vend
32056	N	AP	MACAPA	MACHADO & ANDRADE LTDA	JARDIM MARCO ZERO	DIESEL	2025-12-01	6.3
32057	NE	BA	JEQUIE	D & M COMERCIAL LTDA	CENTRO	DIESEL	2025-12-01	6.5
32058	NE	BA	JEQUIE	JEQUIEZINHO COMERCIO VAREJISTA DE COMBUSTIVEIS...	JEQUIEZINHO	DIESEL	2025-12-01	6.0
32059	NE	BA	JEQUIE	COM DE DER DE PETROLEO BARRETO LTDA	CENTRO	DIESEL	2025-12-01	6.0
32060	NE	BA	JEQUIE	M W COMERCIO DE COMBUSTIVEIS SERVICOS E ALIMEN...	JEQUIEZINHO	DIESEL	2025-12-01	6.2